

Memoire_M2_Biais_de_genre_IA_generative (1)

ID : 9d51ee1fc87fd06e2deb7d9d2a405e8dfe615dcf

 **49%**
Textes suspects

Nom du fichier : Memoire_M2_Biais_de_genre_IA_generative (1).txt
Taille du fichier d'origine : 575,55 ko
Nombre de mots : 15 644

Déposant : Sofiane agouni kaci
Date de dépôt : 2 août 2026
Type de dépôt : interface
date de fin d'analyse : 2 août 2026

Synthèse (section 1/3)

Emplacement des textes suspects dans le document :



Inclus dans le score de textes suspects :

 **Similitudes** **1%**

Passages présentant des similitudes avec des sources retrouvées parmi différentes collections.



 **Détection IA** **49%**

Textes présentant des formulations stylistiquement proches d'un texte généré par une IA.
Ce taux est un indicateur et non une preuve. Vérifiez auprès de l'auteur sa maîtrise des connaissances mentionnées dans le document.



Non inclus dans le pourcentage de textes suspects :

 **Textes entre guillemets** **3%**

Passages entre guillemets, souvent révélateur d'une citation.

Similitudes

1%

Passages présentant des similitudes avec des sources retrouvées parmi différentes collections.



Source principale détectée

N°	Description	Similitudes	Emplacements
1	 aclanthology.org aclanthology.org/2024.cl-3.8.pdf 	<1%	
2	 [2204.06827] How Gender Debiasing Affects Internal Model... ar5iv.labs.arxiv.org/html/2204.06827 	<1%	
3	 Theories of "Gender" in NLP Bias Research arxiv.org/abs/2205.02526 	<1%	
5	 Étude des facteurs de complexité des modèles de langage dans u... inria.hal.science/hal-04623030v1/file/2256.pdf 	<1%	

Source avec similitudes accidentelles

N°	Description	Similitudes	Emplacements
4	 Different Demographic Cues Yield Inconsistent Conclusions Abo... arxiv.org/html/2601.18486v2 	<1%	
6	 Thibault Prouteau – Laboratoire d'Informatique de l'Université d... lium.univ-lemans.fr/thibault-prouteau/ 	<1%	
7	 anr-inextenso.loria.fr anr-inextenso.loria.fr/files/2024/11/JourneeANR_18_11_24.pdf 	<1%	
8	 On Measuring Social Biases in Sentence Encoders arxiv.org/abs/1903.10561 	<1%	
9	 arxiv.org arxiv.org/pdf/2102.08036 	<1%	
10	 aclanthology.org aclanthology.org/2023.emnlp-main.874.pdf 	<1%	



Université Paris Cité · Master VMI Chapitre

UNIVERSITÉ PARIS CITÉ

Master Vision et Machine Intelligente

MÉMOIRE DE MASTER 2

Détection et évaluation des biais de genre dans les modèles d'intelligence artificielle générative

Revue critique, protocole reproductible et étude pilote comparative 3 × 3

Auteur	Nom Prénom	
Statut	Apprenti Data Scientist	
Entreprise	BNP Paribas	
Encadrant universitaire	Sylvain Lobry	
Tuteur entreprise	Imane Loukah	
Année universitaire	2025–2026	

Mémoire académique — résultats pilotes issus d'une exécution reproductible, sans extrapolation fabriquée

Résumé

L'essor des modèles génératifs de langage transforme les activités de rédaction, de recherche, d'assistance et d'aide à la décision. Ces systèmes apprennent cependant sur des corpus qui reflètent des rapports sociaux, des déséquilibres de représentation et des stéréotypes. Ce mémoire étudie la détection des biais de genre dans les modèles d'intelligence artificielle générative. Après avoir posé les fondements des modèles de langage et distingué biais statistique, stéréotype, préjudice représentationnel et préjudice allocationnel, il propose une lecture critique de trois familles de mesures : celles fondées sur les embeddings, celles fondées sur les probabilités et celles fondées sur les générations. La synthèse montre qu'aucune famille ne suffit isolément : une association géométrique n'implique pas nécessairement un comportement discriminatoire, tandis qu'une génération apparemment neutre peut dépendre du prompt, du décodage ou d'un classifieur auxiliaire lui-même biaisé. Le protocole est ensuite implémenté dans une étude pilote de neuf modèles : trois encodeurs multilingual-E5, trois modèles masqués multilingues et trois modèles Qwen2.5-Instruct. L'exécution smoke, réalisée sans erreur, emploie bootstrap, permutations et correction du taux de fausses découvertes. Aucune hypothèse principale n'est rejetée après correction ; les estimations varient néanmoins selon les modèles et métriques, sans amélioration monotone avec la taille. La divergence sémantique des sorties Qwen décroît descriptivement de 0,112 à 0,072 entre 0,5B et 3B. Ces résultats valident la chaîne expérimentale mais, compte tenu du faible effectif, ne certifient aucun modèle.

Mots-clés — IA générative ; grands modèles de langage ; biais de genre ; équité ; WEAT ; SEAT ; LPBS ; CrowS-Pairs ; génération contrôlée ; audit algorithmique.

Abstract

Generative language models increasingly support writing, search, assistance, and decision-related workflows. Yet they are trained on corpora that encode unequal representation, social stereotypes, and historical power relations. This thesis examines how gender bias can be detected in generative AI systems. It first introduces the mathematical foundations of language models and separates statistical bias from stereotypes, representational harms, and allocational harms. It then critically reviews three measurement families: embedding-based, probability-based, and generation-based approaches. The analysis argues that no single family is sufficient: geometric association does not necessarily predict discriminatory behavior, whereas apparently neutral outputs may vary with prompting, decoding, or biased auxiliary classifiers. A reproducible protocol is implemented in a nine-model pilot: three multilingual-E5 encoders, three multilingual masked language models, and three Qwen2.5-Instruct models. The smoke execution completed without errors and used bootstrap, paired permutations, and false-discovery-rate correction. No primary hypothesis was rejected after correction, while estimates still varied across models and metrics with no monotonic improvement by size. Semantic divergence between paired Qwen outputs descriptively decreased from 0.112 to 0.072 between 0.5B and 3B. These findings validate the pipeline but, given the small sample, do not certify any model as fair.

Keywords — generative AI; large language models; gender bias; fairness; WEAT; SEAT; LPBS; counterfactual evaluation; model auditing.

Liste des sigles

Sigle	Définition	
CDA	Counterfactual Data Augmentation	
CEAT	Contextualized Embedding Association Test	
CI	Confidence Interval / intervalle de confiance	
IA	Intelligence artificielle	
LLM	Large Language Model	
LPBS	Log-Probability Bias Score	
MLM	Masked Language Model	
NLG	Natural Language Generation	
NLP/TAL	Natural Language Processing / traitement automatique des langues	
PLL	Pseudo-Log-Likelihood	
SEAT	Sentence Encoder Association Test	
WEAT	Word Embedding Association Test	

Table des matières

- 1. Introduction générale 00
 - 1.1 Contexte et motivation 00
 - 1.2 Problématique 00
 - 1.3 Objectifs et contributions 00

1.4 Périmètre 00

1.5 Organisation du mémoire 00

2. Fondements des modèles d'intelligence artificielle générative 00

2.1 Apprendre une distribution de données 00

2.2 Le Transformer 00

2.3 Préentraînement, adaptation et alignement 00

2.4 Génération et décodage 00

2.5 Modèles ouverts, modèles fermés et niveaux d'accès 00

2.6 Au-delà du texte 00

3. Du biais statistique au préjudice de genre 00

3.1 Le mot « biais » recouvre plusieurs objets 00

3.2 Stéréotype, discrimination et équité 00

3.3 Le genre : une variable sociale, linguistique et méthodologique 00

3.4 Intersectionnalité 00

3.5 Validité d'une mesure de biais 00

4. Comment les biais apparaissent dans une IA générative 00

4.1 Données et sélection du corpus 00

4.2 Objectif d'apprentissage et compression 00

4.3 Adaptation, alignement et sécurité 00

4.4 Prompt, contexte et utilisateur 00

4.5 Chaîne applicative et rétroaction 00

5. État de l'art : des associations lexicales aux audits de LLM 00

5.1 Premiers constats dans les embeddings statiques 00

5.2 Représentations contextualisées 00

5.3 Probabilités masquées et paires minimales 00

5.4 Générations ouvertes 00

5.5 Surveys et consolidation taxonomique 00

5.6 Résultats critiques qui structurent le domaine 00

6. Méthodes fondées sur les embeddings 00

6.1 Principe général 00

6.2 WEAT 00

6.3 SEAT et représentations contextualisées 00

6.4 CEAT et variation contextuelle 00

6.5 Propriétés scientifiques et limites 00

7. Méthodes fondées sur les probabilités 00

7.1 Objet mesuré 00

7.2 LPBS 00

7.3 Pseudo-log-vraisemblance et CrowS-Pairs 00

7.4 StereoSet et compromis avec la capacité linguistique 00

7.5 BBQ et contexte ambigu 00

7.6 Contrôles statistiques 00

8. Méthodes fondées sur les générations 00

8.1 Pourquoi observer le texte produit 00

8.2 Prompts contrefactuels 00

8.3 Regard, sentiment et toxicité 00

8.4 Traits, professions et recommandations 00

8.5 Refus, longueur et style 00

8.6 Répétition et décodage 00

8.7 Juges humains et modèles juges 00

9. Synthèse critique et justification des méthodes retenues 00

9.1 Trois niveaux, trois questions 00

9.2 Pourquoi ces méthodes sont qualifiées de scientifiques 00

9.3 Refus d'un score unique 00

9.4 Menaces à la validité 00

9.5 Positionnement par rapport à la mitigation 00

10. Étude expérimentale pilote reproductible 00

10.1 Questions de recherche et statut de l'expérience 00

10.2 Plan comparatif 3 × 3 00

10.3 Paramètres, stimuli et traçabilité 00

10.4 Résultats fondés sur les embeddings 00

10.5 Résultats fondés sur les probabilités 00

10.6 Résultats fondés sur les générations 00

10.7 Coût de calcul et compromis opérationnel 00

10.8 Synthèse comparative des neuf modèles 00

10.9 Menaces à la validité 00

10.10 Reproductibilité et passage au profil complet 00

11. Traduction dans un contexte d'entreprise et financier 00

11.1 Du benchmark au cas d'usage 00

11.2 Gouvernance du risque 00

11.3 Seuils et décision 00

11.4 Surveillance continue 00

11.5 Limites de l'automatisation de l'audit 00

12. Discussion, limites et perspectives 00

12.1 Ce que le protocole permet d'établir 00

12.2 Limites du mémoire 00

12.3 Passage du pilote au benchmark confirmatoire 00

12.4 Perspectives scientifiques 00

Conclusion générale 00

Références 00

Université Paris Cité · Master VMI Mémoire de Master 2

Année universitaire 2025–2026 Page 1

1. Introduction générale

1.1 Contexte et motivation

L'intelligence artificielle générative désigne une classe de systèmes capables de produire de nouveaux contenus — texte, image, audio, vidéo ou code — à partir d'une distribution apprise sur de grands corpus. Dans le domaine du langage, les grands modèles de langage, ou *large language models* (LLM), ont rendu cette capacité accessible par une interface conversationnelle. Ils peuvent résumer un document, proposer une réponse, rédiger un courriel, extraire une information ou assister une analyse. L'innovation ne réside donc pas seulement dans la qualité linguistique obtenue : elle tient aussi à la généralité d'un même modèle, adaptable à de nombreux usages par instruction, exemples ou ajustement supplémentaire [1]–[4]. Cette polyvalence accélère l'adoption, mais elle diffuse simultanément les défauts du modèle dans une pluralité de processus.



Un modèle de langage apprend les régularités de ses données. Or les textes disponibles à grande échelle décrivent une société inégalitaire, emploient des catégories imparfaites et accordent une visibilité différente aux groupes sociaux. Apprendre fidèlement ces régularités n'est pas synonyme de produire des comportements souhaitables. Une association fréquente entre certains métiers et le masculin peut être statistiquement exacte dans le corpus et néanmoins contribuer, dans un système déployé, à renforcer un stéréotype ou à décourager une population. Le problème n'est donc pas réductible à une erreur technique : il implique une définition du préjudice, un contexte d'usage, des personnes affectées et un choix normatif sur le comportement attendu [5], [6].

Cette difficulté devient particulièrement sensible en entreprise. Un assistant génératif peut intervenir dans la rédaction de descriptions de poste, la synthèse de profils, la préparation de communications, la recherche documentaire ou le support aux collaborateurs. Dans un établissement financier, l'exigence de maîtrise des risques s'ajoute aux enjeux de conformité, de réputation, de sécurité et de qualité. Cependant, le présent mémoire ne prétend ni auditer un système précis de BNP Paribas ni inférer des pratiques internes non documentées. Le contexte de l'alternance motive un cas d'usage : construire une méthode scientifique permettant d'évaluer le biais de genre avant qu'un modèle ou une application ne soit considéré comme acceptable pour un usage donné.

1.2 Problématique

La question centrale est la suivante : **comment détecter et quantifier de manière scientifiquement défendable les biais de genre d'un modèle génératif de langage, alors que les résultats varient avec le niveau observé, le protocole, le prompt, la langue et le contexte d'usage ?** Cette formulation contient plusieurs tensions. Premièrement, le biais peut être recherché dans une représentation interne, dans une distribution de probabilités ou dans un texte généré. Deuxièmement, une métrique peut être reproductible sans mesurer le préjudice réellement pertinent. Troisièmement, l'absence de différence statistiquement détectable dans un benchmark ne prouve pas l'absence de risque. Enfin, le genre n'est pas une variable binaire simple : il associe des dimensions sociales, identitaires, linguistiques et grammaticales que les jeux de données historiques confondent souvent [7], [8].

Ce mémoire défend une thèse méthodologique : les approches fondées sur les embeddings, les probabilités et les générations doivent être combinées, mais non fusionnées naïvement en un score unique. Chacune observe un objet différent et répond à une question distincte. Les embeddings renseignent sur la géométrie des associations apprises ; les probabilités révèlent des préférences conditionnelles dans des environnements contrôlés ; les générations évaluent un comportement proche de l'usage, au prix d'une variance et d'une dépendance au protocole plus élevées. La triangulation permet de repérer des contradictions fécondes : un modèle peut sembler peu biaisé selon WEAT et produire néanmoins des sorties asymétriques, ou préférer une phrase stéréotypée sans la générer spontanément après alignement.

1.3 Objectifs et contributions

Le premier objectif consiste à fournir les définitions nécessaires à un lecteur de niveau Master 2 : modèle génératif, modèle de langage, représentation vectorielle, probabilité conditionnelle, stéréotype, biais social, équité, préjudice représentationnel et préjudice allocationnel. Le deuxième objectif est de reconstruire l'état de l'art en distinguant les articles fondateurs des extensions et des critiques. Le troisième est de justifier le choix des trois familles de mesure à partir de leurs objets mathématiques et de leurs conditions d'emploi. Le quatrième est d'implémenter un protocole expérimental reproductible et d'en analyser une exécution pilote, sans extrapoler au-delà des observations effectivement produites.

La contribution n'est donc pas une nouvelle métrique. Elle est une architecture d'évaluation reproductible et critique, centrée sur le biais de genre, compatible avec plusieurs architectures ouvertes et structurée autour d'une comparaison 3×3 : trois modèles de tailles différentes dans chacune des trois familles. Elle explicite les hypothèses, les unités statistiques, les paramètres de génération, les contrôles linguistiques, les analyses de sensibilité et les règles de compte rendu. Elle traite également les refus de réponse, la variabilité des métriques auxiliaires et la multiplicité des tests. L'exécution présentée au chapitre 10 relève d'un profil pilote volontairement réduit ; ses valeurs sont analysées comme des observations exploratoires, non comme une certification d'équité.

1.4 Périmètre

L'expression « IA générative » est large. Les taxonomies embedding-based, probability-based et generation-based ont été principalement formalisées pour les modèles de langage [14], [15]. Le cœur du mémoire porte donc sur la génération textuelle. Les modèles d'images et multimodaux sont mentionnés afin de situer le domaine, mais une évaluation visuelle rigoureuse demanderait d'autres ressources : classifieurs d'attributs, annotations iconographiques, mesures de représentation des professions, protocoles de perception et analyse des biais propres aux jeux d'images. Étendre directement WEAT ou CrowS-Pairs à une image sans redéfinir l'objet mesuré créerait une fausse continuité méthodologique.

Le biais de genre est privilégié parce qu'il a donné lieu à une littérature fondatrice abondante, depuis les analogies dans les embeddings jusqu'aux audits de générations. Cette spécialisation n'autorise pas à isoler le genre des autres rapports sociaux. Les effets intersectionnels avec l'âge, l'origine perçue, la classe sociale, le handicap ou l'orientation sexuelle peuvent modifier les résultats. Le protocole prévoit donc une extension intersectionnelle, mais le noyau comparatif porte sur des contrastes de genre contrôlés. Le choix est pragmatique et doit être déclaré comme une limite, non présenté comme une ontologie exhaustive.

1.5 Organisation du mémoire

Le chapitre 2 présente les fondements techniques des modèles génératifs de langage. Le chapitre 3 clarifie les concepts de biais et de genre ainsi que les niveaux de préjudice. Le chapitre 4 décrit les mécanismes par lesquels un biais peut entrer, se transformer ou devenir visible dans un système génératif. Le chapitre 5 reconstruit l'état de l'art. Les chapitres 6 à 8 étudient respectivement les méthodes fondées sur les embeddings, les probabilités et les générations. Le chapitre 9 propose une synthèse critique et justifie la triangulation. Le chapitre 10 décrit le protocole, son implémentation et les résultats de l'étude pilote 3 × 3. Le chapitre 11 traduit ces enseignements en exigences de gouvernance pour un contexte d'entreprise. Enfin, le chapitre 12 discute la portée des observations, les limites et les prolongements nécessaires.

Tableau 1 — Les trois familles de mesure retenues et leur complémentarité. Source : synthèse de [14], [15].

Famille	Objet observé	Accès requis	Forces	Limites principales
Embedding-based	Géométrie des représentations	États cachés ou encodeur	Diagnostic interne ; tests statistiques ; faible coût	Dépend du pooling et des stimuli ; validité comportementale limitée
Probability-based	Probabilités de tokens ou de séquences	Logits ou log-probabilités	Paires contrôlées ; analyse fine ; répétabilité	Calibration et tokenisation ; incompatibilité avec certaines API fermées
Generation-based	Texte effectivement généré	Accès boîte noire suffisant	Proche de l'usage ; applicable aux modèles fermés	Variance du décodage ; juges auxiliaires ; coût ; refus de répondre

2. Fondements des modèles d'intelligence artificielle générative

2.1 Apprendre une distribution de données

Un modèle génératif vise à approximer une distribution de données inconnue. Dans le cas du texte, une séquence de tokens $x = (x_1, \dots, x_n)$ est généralement factorisée selon la règle de la chaîne. Un modèle autorégressif estime la probabilité du prochain token conditionnellement aux tokens précédents. L'apprentissage par maximum de vraisemblance minimise alors la somme des log-probabilités négatives sur un corpus. Cette opération ne « comprend »

pas le monde au sens humain ; elle ajuste des paramètres afin que les séquences observées reçoivent une probabilité élevée. Pourtant, à grande échelle, les représentations obtenues soutiennent des comportements complexes, notamment l'apprentissage en contexte [3].

$$p\theta(x_1, \dots, x_n) = \prod_{i=1}^n p\theta(x_i \mid x_1, \dots, x_{i-1})$$

$$L(\theta) = - \sum_{x \in D} \sum_i \log p\theta(x_i \mid x_{<i})$$

Cette factorisation explique pourquoi le biais peut apparaître comme une différence de probabilité. Si, à contexte identique, un terme masculin augmente davantage la probabilité de « ingénieur » qu'un terme féminin, le modèle exprime une asymétrie conditionnelle. Toutefois, cette asymétrie peut provenir de plusieurs causes : fréquence du corpus, polysémie, accord grammatical, tokenisation, information réellement pertinente ou stéréotype. Une expérience valide doit isoler autant que possible ces explications concurrentes.

Les modèles masqués, dont BERT constitue une référence, utilisent un objectif différent : prédire un token caché en tenant compte du contexte gauche et droit [2]. Ils ne sont pas initialement des générateurs autorégressifs, mais leurs probabilités conditionnelles et leurs représentations contextualisées sont largement utilisées pour étudier le biais. Cette distinction est importante pour le protocole : une pseudo-log-vraisemblance obtenue en masquant successivement des tokens n'est pas identique à la vraisemblance d'un modèle causal. Comparer directement les valeurs brutes de familles architecturales différentes serait incorrect.

2.2 Le Transformer

Le Transformer remplace la récurrence par des mécanismes d'attention qui mettent en relation les positions d'une séquence [1]. Pour une matrice de requêtes Q, de clés K et de valeurs V, l'attention produit une moyenne pondérée des valeurs. Le facteur $\sqrt{d_k}$ stabilise les produits scalaires lorsque la dimension augmente. L'attention multi-têtes répète cette opération dans plusieurs sous-espaces et combine les résultats. Des connexions résiduelles, normalisations et réseaux feed-forward complètent chaque bloc.

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k})V$$

Les embeddings initiaux codent les tokens et leur position. À travers les couches, la représentation d'un token devient contextuelle : le vecteur de « cadre » ne sera pas identique dans « cadre bancaire » et « cadre dirigeante ». Cette contextualisation motive SEAT et CEAT, mais complique l'évaluation. Il faut décider quelle couche extraire, quel token représenter, comment agréger les sous-tokens et comment former une représentation de phrase. Deux études nominalement fondées sur « les embeddings de BERT » peuvent donc mesurer des objets différents.

2.3 Préentraînement, adaptation et alignement

Le préentraînement apprend des régularités générales sur un grand corpus. L'adaptation peut prendre la forme d'un fine-tuning supervisé, d'un ajustement par préférences, d'instructions, de récupération documentaire ou de prompting. Chaque étape peut transformer le biais. Un corpus d'instructions plus équilibré peut réduire certaines sorties stéréotypées, tandis qu'un classifieur de récompense peut surtout enseigner au modèle à refuser des questions sensibles. Le comportement final n'est donc pas une lecture transparente du préentraînement. Il résulte d'une chaîne de composants, souvent partiellement inconnue pour les modèles propriétaires.

Le terme *foundation model* souligne précisément cette centralité : un modèle entraîné largement devient la base de multiples applications, de sorte que ses défauts peuvent être hérités en aval [4]. Cette homogénéisation crée un levier d'amélioration mais aussi un risque systémique. Dans une organisation, évaluer uniquement l'interface finale sans documenter le modèle, la version, le prompt système et les outils connectés compromet la reproductibilité. Inversement, auditer seulement le modèle de base peut manquer les effets de l'orchestration réelle.

2.4 Génération et décodage

À l'inférence, le modèle produit une distribution sur le vocabulaire. Le décodage glouton choisit le token le plus probable

; l'échantillonnage tire un token selon une distribution éventuellement transformée par une température. Le top-k restreint les candidats aux k tokens les plus probables ; le top-p conserve le plus petit ensemble dont la masse cumulée dépasse p. Ces décisions influencent la diversité, mais aussi la fréquence des sorties rares, toxiques ou stéréotypées. Une comparaison de biais sans paramètres de décodage communs peut surtout comparer deux politiques d'échantillonnage.

$$p^T(x_i \mid x_{1:i}) = \text{softmax}(z_i / T)$$

Lorsque T tend vers zéro, la distribution se concentre. Lorsque T augmente, les alternatives moins probables deviennent plus accessibles. Pour un audit generation-based, une seule sortie déterministe sous-estime la distribution comportementale ; mais des centaines d'échantillons à forte température peuvent surestimer des comportements marginaux. Le protocole proposé sépare donc un régime déterministe, utile pour la répétabilité, et un régime stochastique contrôlé, utile pour estimer un risque de génération.

2.5 Modèles ouverts, modèles fermés et niveaux d'accès

Un modèle ouvert permet généralement d'accéder aux poids, logits et états cachés. Il autorise les trois familles d'évaluation, au prix d'exigences de calcul et de décisions d'implémentation. Une API fermée peut ne fournir que du texte, parfois des log-probabilités partielles. Dans ce cas, les mesures d'embeddings sont impossibles et les mesures probabilistes limitées. Les générations deviennent le dénominateur commun, mais les mises à jour silencieuses du fournisseur peuvent altérer la comparabilité longitudinale.

Le niveau d'accès doit être traité comme une propriété expérimentale. Une étude ne peut pas conclure qu'une famille est « meilleure » indépendamment de l'objet et de l'accès. Les mesures intrinsèques sont utiles pour comprendre et comparer des modèles ouverts ; les mesures comportementales sont nécessaires pour les systèmes fermés ou fortement alignés. La scientificité provient ici de la définition de la variable, de la traçabilité et du contrôle, non du caractère interne ou externe de la mesure.

2.6 Au-delà du texte

Les modèles de diffusion génèrent des images en apprenant à inverser progressivement un processus de bruitage. Les systèmes multimodaux relient texte et image dans un espace partagé ou utilisent un LLM comme composant de raisonnement. Ils peuvent manifester un biais de genre par la sous-représentation de femmes dans certaines professions, la sexualisation, des attributs visuels stéréotypés ou une qualité différenciée. Cependant, le nombre d'images, le classifieur de genre, la formulation du prompt et les catégories visuelles introduisent des choix normatifs analogues à ceux étudiés pour le texte, auxquels s'ajoutent les difficultés de perception.

Le présent mémoire choisit donc une profondeur méthodologique sur le texte plutôt qu'une couverture superficielle de toutes les modalités. Cette délimitation reste compatible avec la formation Vision et Machine Intelligente : les principes de contrefactualité, de répétition, de contrôle des générateurs, d'analyse de sensibilité et de documentation se transfèrent aux audits multimodaux. Les métriques, elles, doivent être redéfinies à partir du contenu effectivement observé.

3. Du biais statistique au préjudice de genre

3.1 Le mot « biais » recouvre plusieurs objets

En statistique, le biais d'un estimateur est l'écart entre son espérance et le paramètre visé. En apprentissage, le terme peut désigner une hypothèse inductive, un déséquilibre de données, une erreur systématique ou une disparité entre groupes. Dans le débat public, il évoque plutôt un traitement injuste ou un stéréotype. Employer le même mot pour ces

objets crée des glissements : détecter une différence moyenne ne suffit pas à établir une injustice, tandis qu'une procédure statistiquement calibrée peut maintenir une structure socialement défavorable.

Blodgett et al. montrent que de nombreux travaux en NLP motivent insuffisamment ce qu'ils appellent biais : quel comportement est nuisible, envers qui, selon quelle théorie et dans quel contexte [5] ? Cette critique impose une discipline. Le mémoire utilise « biais de genre » pour désigner une différence systématique liée à des marqueurs de genre qui produit ou signale un risque de représentation dévalorisante, d'effacement, de stéréotypie ou de traitement inéquitable. La mesure quantitative est un indicateur de ce construit, pas le construit lui-même.

3.2 Stéréotype, discrimination et équité

Un stéréotype associe de façon généralisée un groupe à un attribut, un rôle ou un comportement. Il peut être descriptif — « les hommes occupent plus souvent tel poste dans le corpus » — ou prescriptif — « ce poste convient mieux aux hommes ». Un modèle probabiliste n'explique pas cette distinction ; il apprend des cooccurrences. L'auditeur doit donc examiner le contexte et le potentiel de renforcement. Une association apparemment positive, comme femmes-empathie, peut restreindre les rôles sociaux tout autant qu'une association explicitement négative.

La discrimination concerne un traitement défavorable fondé sur une caractéristique protégée ou qui produit un désavantage injustifié. Dans un système génératif, le texte n'alloue pas toujours directement une ressource. Mais il peut influencer une décision, décrire différemment des personnes, proposer des recommandations asymétriques ou normaliser certaines identités. On distingue ainsi les préjudices représentationnels, qui portent sur la visibilité, la dignité et les associations, des préjudices allocationnels, qui affectent l'accès à une opportunité, un service ou une ressource [4], [5].

L'équité n'a pas une définition universelle. L'égalité des taux d'erreur, la parité démographique, la calibration ou la justice contrefactuelle peuvent être incompatibles. Pour une génération ouverte, ces métriques issues de la classification ne s'appliquent pas directement : la sortie est une séquence, plusieurs réponses peuvent être acceptables et le dommage dépend du sens. Il faut construire des observables — regard, toxicité, traits attribués, refus, longueur, recommandation — et justifier leur lien avec le risque étudié.

Tableau 2 — Du signal mesuré au préjudice potentiel : niveaux qu'il convient de ne pas confondre.

Niveau	Manifestation possible	Exemple d'audit	Risque d'interprétation
Représentation	Association femmes-famille, hommes-carrière	WEAT/SEAT sur lexiques contrôlés	Confondre association descriptive et jugement normatif
Probabilité	Préférence pour une phrase stéréotypée	Paires minimales et score de log-vraisemblance	Attribuer au biais un effet de fréquence ou de grammaticalité
Génération	Différences de compétences ou de ton selon le genre	Prompts contrefactuels et annotation	Dépendance au prompt, au décodage et au juge
Allocation	Classement, recommandation ou accès différencié	Évaluation sur tâche et métriques de groupe	Extrapoler depuis un benchmark artificiel vers une décision réelle

3.3 Le genre : une variable sociale, linguistique et méthodologique

Les premiers benchmarks réduisent souvent le genre à deux listes de pronoms ou de prénoms. Cette réduction a facilité la construction de paires minimales et l'analyse statistique, mais elle confond sexe assigné, identité de genre, expression, pronom et genre grammatical. Devinney et al. montrent que les travaux de NLP mobilisent des théories implicites et souvent incohérentes du genre [8]. Dev et al. décrivent les préjudices d'exclusion et les difficultés de représentation non binaire [7]. Une étude scientifiquement honnête doit donc dire exactement quel signal linguistique est manipulé.

Dans le noyau expérimental proposé, « féminin » et « masculin » désignent des marqueurs linguistiques contrôlés :

pronoms, accords, titres et prénoms prétestés. Ils ne prétendent pas capturer l'ensemble des identités. Un volet séparé inclut « iel » et « they/them », mais ses résultats ne doivent pas être agrégés comme un troisième point sur un axe numérique. La fréquence plus faible de certaines formes, la segmentation en sous-tokens et la connaissance linguistique du modèle constituent des facteurs de confusion. La qualité de langue doit être évaluée en parallèle.

Le français ajoute le genre grammatical. Un adjectif ou un participe peut rendre le genre visible même lorsque l'information sociale n'est pas pertinente. Traduire littéralement un benchmark anglais risque de modifier la syntaxe, la naturalité et le nombre de tokens. Le protocole exige une adaptation humaine et une validation par locuteurs, plutôt qu'une traduction automatique non contrôlée. Les résultats français et anglais seront rapportés séparément avant toute comparaison.

3.4 Intersectionnalité

Le biais de genre n'agit pas indépendamment de l'origine perçue, de l'âge, du statut social ou du handicap. Un modèle peut produire des descriptions différentes pour « une ingénieure » et « une ingénieure voilée », sans que l'effet combiné soit la somme des deux effets isolés. Les analyses unidimensionnelles peuvent masquer ce phénomène. HolisticBias élargit la couverture par de nombreux descripteurs, mais le produit cartésien de catégories produit aussi des combinaisons artificielles ou blessantes [32].

Une extension intersectionnelle doit être préenregistrée, limitée par une hypothèse et discutée avec les personnes concernées. L'augmentation du nombre de groupes accroît la multiplicité des tests et réduit la puissance statistique. Dans le profil complet du notebook, le noyau genre-profession restera donc distinct d'un module exploratoire intersectionnel. Cette séparation évite de transformer une ambition inclusive en exploration opportuniste de milliers de différences.

3.5 Validité d'une mesure de biais

La validité de construit demande si la métrique représente bien le concept annoncé. La validité interne demande si l'effet observé peut être attribué au genre plutôt qu'à la longueur, à la fréquence ou à la grammaire. La validité externe demande si le résultat se généralise à d'autres prompts, modèles, langues et usages. La fidélité concerne la stabilité de la mesure. Une p-value faible ne garantit aucune de ces propriétés ; elle quantifie un résultat sous un modèle statistique et un plan d'échantillonnage.

Les benchmarks sont eux-mêmes des instruments. Blodgett et al. inventorient des pièges tels que des phrases peu naturelles, une confusion entre groupe social et nationalité, ou l'absence de lien explicite entre exemple et préjugé [6]. Goldfarb-Tarrant et al. ne trouvent pas de corrélation fiable et générale entre métriques intrinsèques et biais applicatif [35]. Le protocole doit donc accumuler des preuves complémentaires plutôt que chercher une mesure définitive.

Principe de prudence — Un score de biais est une mesure conditionnelle à un modèle, un instrument, une langue et un usage. Une valeur faible ne constitue pas un certificat d'absence de discrimination.

4. Comment les biais apparaissent dans une IA générative

4.1 Données et sélection du corpus

Les corpus Web ne sont pas un échantillon neutre de la population. Ils surreprésentent les personnes qui publient, les langues dominantes, les contenus optimisés pour la visibilité et les événements jugés dignes d'être documentés. Les filtres de qualité peuvent renforcer ce déséquilibre s'ils privilégient certains registres ou sources. Les déduplications,

classifieurs de toxicité et listes de blocage introduisent à leur tour des erreurs différentielles. Un texte mentionnant une identité minoritaire peut être classé à tort comme toxique parce que le classifieur a appris une corrélation entre le terme identitaire et l'insulte.

Le biais de représentation n'est pas uniquement une question de quantité. La distribution des rôles, des verbes et des évaluations compte. Si les biographies de femmes évoquent davantage la famille et celles des hommes davantage les réalisations, un modèle peut reproduire cette asymétrie même avec un nombre équilibré de documents. Les articles sur les embeddings ont précisément montré que la géométrie encode des structures d'association et pas seulement des comptes bruts [16], [17].

4.2 Objectif d'apprentissage et compression

Le maximum de vraisemblance récompense la prédiction des régularités fréquentes. Il n'existe pas, dans l'objectif standard, de terme imposant une représentation équitable. Le modèle compresse des variations complexes dans un nombre fini de paramètres ; les corrélations utiles et nuisibles sont apprises ensemble. La grande capacité n'élimine pas ce mécanisme. Elle peut améliorer la sensibilité au contexte tout en mémorisant des associations plus fines.

Le passage par la tokenisation peut amplifier certaines disparités. Un prénom fréquent est représenté par un token unique, tandis qu'un prénom moins fréquent est fragmenté. Les scores de séquence additionnent alors un nombre différent de termes. Les langues morphologiquement riches subissent davantage de fragmentation. Toute comparaison probabiliste doit soit contrôler le nombre de tokens, soit normaliser explicitement et vérifier que la conclusion résiste à plusieurs agrégations.

4.3 Adaptation, alignement et sécurité

L'apprentissage par préférences humaines et les politiques de sécurité cherchent à réduire les sorties nuisibles. Ils peuvent améliorer le comportement visible sans effacer les associations internes. Gonen et Goldberg ont déjà montré, pour les embeddings, qu'une méthode de *debiasing* peut dissimuler le biais selon un test tout en conservant une structure récupérable [18]. Dans les LLM, un phénomène analogue peut opposer une probabilité stéréotypée et une réponse finale prudente.

Les refus sont eux-mêmes un objet d'équité. Si le modèle refuse davantage de répondre à propos d'un groupe que d'un autre, une métrique de toxicité faible peut masquer un service dégradé. Le protocole doit mesurer séparément le taux de refus, l'utilité et les contenus. Il ne faut pas compter une absence de génération comme une réponse neutre. De même, un avertissement moral précédant une réponse stéréotypée ne neutralise pas nécessairement cette dernière.

4.4 Prompt, contexte et utilisateur

Un LLM est une fonction conditionnelle : modifier une instruction, l'ordre des exemples ou la langue peut changer la sortie. Le prompt système, souvent invisible, encadre le comportement. Les évaluations basées sur quelques formulations peuvent donc confondre biais du modèle et fragilité du prompt. La solution n'est pas de chercher un prompt « parfait », mais de définir une famille de formulations, d'échantillonner ou de bloquer leur effet, puis de rapporter la dispersion.

Le contexte peut légitimement rendre le genre pertinent. Une recommandation médicale ou une règle grammaticale ne doit pas nécessairement être invariante. À l'inverse, une description de compétence ou une proposition de carrière devrait souvent l'être. L'audit contrefactuel exige une hypothèse d'invariance liée au cas d'usage. Remplacer mécaniquement « il » par « elle » dans toute phrase ne crée pas toujours une paire sémantiquement équivalente.

4.5 Chaîne applicative et rétroaction

Une application générative combine fréquemment un moteur de recherche, un modèle, des règles, un post-traitement et une interface. Un biais peut provenir du classement des documents récupérés plutôt que du LLM. Il peut aussi être

introduit par un résumé qui compresse différemment des informations. Une évaluation de composant doit donc être complétée par une évaluation de bout en bout.

Les sorties peuvent être réutilisées comme données, créant une boucle de rétroaction. Des descriptions de poste générées puis publiées deviennent du texte Web futur. Si elles renforcent une association, la génération suivante peut l'apprendre. La gouvernance doit ainsi considérer le cycle de vie, la surveillance et les changements de modèle. Le cadre NIST organise cette gestion autour des fonctions gouverner, cartographier, mesurer et gérer [39].

5. État de l'art : des associations lexicales aux audits de LLM

5.1 Premiers constats dans les embeddings statiques



Bolukbasi et al. ont popularisé l'exemple « man : computer programmer :: woman : homemaker » et proposé une méthode de neutralisation de directions de genre [16]. L'article a joué un rôle fondateur : il rendait visible, par des opérations géométriques simples, la présence de stéréotypes dans des représentations utilisées en aval. Mais l'analogie n'est ni une mesure générale ni une définition du préjudice. Elle dépend du modèle, du vocabulaire et de l'opération vectorielle.

Caliskan, Bryson et Narayanan ont ensuite introduit WEAT, adaptation de l'Implicit Association Test aux embeddings [17]. Des ensembles de cibles et d'attributs sont comparés par similarité cosinus, puis une taille d'effet et un test de permutation sont calculés. Le travail a montré que des associations humaines connues sont récupérables dans GloVe. Sa force tient à la formalisation statistique. Sa limite tient au saut d'interprétation entre association sémantique, biais humain et dommage d'un système.

Garg et al. ont utilisé les embeddings pour quantifier l'évolution de stéréotypes de genre et d'origine sur un siècle [20]. Cette perspective diachronique rappelle qu'une représentation encode aussi un état historique. Supprimer toute association risque d'effacer une information utile à l'analyse sociale ; la conserver sans contrôle peut la reproduire dans une application. La finalité détermine donc la politique de correction.

5.2 Représentations contextualisées

Avec BERT et les encodeurs de phrases, un mot ne possède plus un vecteur unique. May et al. proposent SEAT, qui insère les stimuli de WEAT dans des patrons supposés sémantiquement neutres et applique le test aux représentations de phrases [19]. La méthode offre une continuité avec WEAT, mais la notion de patron « blanchi sémantiquement » est fragile : « This is X » ou « X is here » peut interagir avec le tokenizer et la syntaxe.

CEAT échantillonne des occurrences contextuelles et utilise une méta-analyse à effets aléatoires afin de modéliser la variation [21]. Cette approche reconnaît que l'association n'est pas fixe. Elle est particulièrement pertinente pour un protocole moderne, mais plus coûteuse et dépendante du corpus de contextes. Elle ne remplace pas SEAT ; elle répond à une question différente, celle de l'association moyenne à travers une distribution de contextes.

Les études critiques constatent une forte sensibilité à la couche, au pooling et aux stimuli [36], [37]. Une comparaison qui sélectionne après coup la couche donnant le résultat le plus spectaculaire est une forme de flexibilité analytique. Le protocole doit préenregistrer une couche principale ou rapporter une analyse multivers complète.

5.3 Probabilités masquées et paires minimales

Kurita et al. proposent LPBS pour mesurer, dans un modèle masqué, une association entre cible de genre et attribut tout



en corrigeant la probabilité a priori du terme de genre [22]. Webster et al. introduisent DisCo et étudient la réduction du biais par augmentation contrefactuelle et dropout [23]. Ces méthodes interrogent directement la distribution prédictive plutôt que la géométrie. Elles sont adaptées aux professions, mais restent dépendantes des patrons et de la segmentation.

CrowS-Pairs fournit 1 508 paires de phrases couvrant neuf types de biais [24]. Le score compare la pseudo-log-vraisemblance d'une phrase stéréotypée à celle d'une variante moins stéréotypée. StereoSet propose des alternatives stéréotypées, anti-stéréotypées et dénuées de sens, aux niveaux intra- et interphrase [25]. L'introduction d'une alternative incohérente cherche à éviter qu'un modèle paraisse équitable uniquement parce qu'il comprend mal le langage.



BBQ déplace l'analyse vers la question-réponse [26]. Chaque exemple possède un contexte ambigu, dans lequel le modèle devrait reconnaître l'incertitude, et un contexte désambiguïé, dans lequel l'information permet une réponse correcte. Cette structure est conceptuellement forte : elle sépare l'usage d'un stéréotype comme raccourci de la capacité à utiliser une information pertinente. Elle est toutefois ancrée dans des catégories et situations états-unienues.

WinoBias et Winogender ciblent la coréférence entre pronoms et professions [10], [11]. Ils ont démontré des écarts entre configurations pro- et anti-stéréotypées. Ces ressources sont influentes mais historiquement binaires et centrées sur l'anglais. Des révisions récentes ont relevé des problèmes de cohérence dans certains schémas [12]. Elles restent utiles si l'on documente leur objet et si l'on évite d'en faire une mesure universelle du genre.

5.4 Générations ouvertes

Sheng et al. proposent d'évaluer le *regard*, c'est-à-dire l'attitude exprimée envers un groupe, plutôt que de confondre sentiment général et représentation du groupe [28]. Une phrase peut avoir un sentiment négatif parce qu'elle décrit une discrimination subie, tout en portant un regard respectueux sur la personne. Cette distinction illustre la nécessité d'un construit adapté au texte généré.

RealToxicityPrompts fournit 100 000 amorces issues du Web accompagnées de scores de toxicité [29]. L'étude montre que des modèles peuvent générer un texte toxique depuis des prompts apparemment anodins. BOLD cible cinq domaines, dont les professions et le genre, avec des mesures de sentiment, toxicité et polarité [30]. HONEST propose des patrons et lexiques dans six langues, dont le français [31]. HolisticBias étend la couverture à près de 600 descripteurs sur treize axes démographiques [32].



Ces ressources rendent possible un audit de modèles fermés, mais déplacent le problème vers l'évaluation des sorties. Les classifieurs de toxicité ou de sentiment peuvent avoir leurs propres biais. Les lexiques ignorent le contexte. Une annotation humaine améliore la validité, mais introduit désaccord, coût et exposition à des contenus difficiles. Un protocole responsable combine plusieurs juges et rapporte leur accord au lieu de masquer les divergences.

5.5 Surveys et consolidation taxonomique

Gallegos et al. organisent les métriques selon le niveau auquel elles opèrent : embeddings, probabilités et texte généré [14]. Chu, Wang et Zhang proposent une taxonomie presque identique, complétée par les étapes de mitigation [15]. Cette convergence justifie le choix des trois familles comme colonne vertébrale du mémoire. Elle ne signifie pas que toutes les métriques d'une famille sont équivalentes, ni que les frontières sont hermétiques. HONEST, par exemple, peut servir à une complétion masquée ou ouverte.

Le bénéfice scientifique de la taxonomie est de rendre explicite l'objet observé et l'accès requis. Elle empêche de comparer une similarité cosinus à un taux de toxicité comme s'il s'agissait de deux estimations du même paramètre. Elle facilite également un protocole par couches : diagnostic interne, préférence contrôlée, comportement de bout en bout. Son risque est de donner une impression de complétude. Des mesures sur tâches, des audits humains, des analyses causales et des études d'impact organisationnel restent nécessaires.

Tableau 3 — Méthodes et ressources fondatrices retenues pour le benchmark.

Méthode / ressource	Référence	Principe	Usage dans le protocole
WEAT	Caliskan et al. [17]	Différence normalisée d'associations cosinus	Socle embedding statique et contrôle de validité
SEAT	May et al. [19]	Extension de WEAT aux phrases encodées	Audit d'encodeurs et variantes de pooling
LPBS	Kurita et al. [22]	Rapport de probabilités corrigé par le prior	Biais genre-profession pour MLM
CrowS-Pairs	Nangia et al. [24]	PLL de paires stéréotypée/anti-stéréotypée	Test probabiliste contrefactuel
StereoSet	Nadeem et al. [25]	Préférence stéréotype/anti-stéréotype/non-sens	Contrôle simultané du biais et de la qualité
Regard	Sheng et al. [28]	Évaluation du regard envers un groupe dans les sorties	Mesure générationnelle principale
BOLD	Dhamala et al. [30]	Prompts ouverts et métriques de sentiment/toxicité	Extension à professions et domaines
HONEST	Nozza et al. [31]	Complétions blessantes multilingues	Volet français et anglais
HolisticBias	Smith et al. [32]	Descripteurs et patrons sur 13 axes	Couverture intersectionnelle et tests de robustesse

5.6 Résultats critiques qui structurent le domaine

Gonen et Goldberg montrent que des méthodes de neutralisation peuvent réduire un indicateur explicite tout en laissant le genre récupérable dans la structure locale des embeddings [18]. Goldfarb-Tarrant et al. observent qu'aucune corrélation fiable et générale ne relie les métriques intrinsèques aux biais applicatifs à travers leurs scénarios [35]. Orgad et Belinkov soulignent également que biais interne et externe ne se déplacent pas nécessairement ensemble [38]. Ces résultats interdisent une conclusion du type « WEAT diminue, donc le système est équitable ».

Blodgett et al. examinent les pièges des benchmarks [6]. Delobelle et al. montrent que choix de templates, embeddings et métriques rendent les mesures intrinsèques difficilement comparables [36]. Pikuliak et al. identifient des problèmes théoriques et empiriques dans les méthodes de remplissage de mots, notamment StereoSet et CrowS-Pairs [37]. L'état de l'art ne converge donc pas vers un indicateur roi ; il converge vers la nécessité de documenter plusieurs preuves et leurs limites.

Cette conclusion motive le protocole du chapitre 10. Les trois familles sont retenues non parce qu'elles seraient parfaites, mais parce qu'elles sont formalisées, reproductibles, complémentaires et appuyées par des articles fondateurs. Leur usage scientifique suppose des hypothèses, des contrôles, des tailles d'effet, des intervalles de confiance et une interprétation limitée au construit observé.

6. Méthodes fondées sur les embeddings

6.1 Principe général

Une représentation vectorielle place des unités linguistiques dans un espace où une mesure de proximité résume certaines régularités d'usage. Pour deux vecteurs u et v , la similarité cosinus normalise le produit scalaire par les normes. Cette normalisation rend la mesure indépendante de l'échelle, mais pas de l'anisotropie de l'espace, de la fréquence des mots ni du choix de la couche. Un biais d'association est recherché en comparant la proximité de cibles — par exemple des prénoms féminins et masculins — à des attributs tels que carrière et famille.

$$\cos(u,v) = (u \cdot v) / (\|u\|_2 \|v\|_2)$$

La simplicité géométrique est utile pour l'inspection et la répétition. Elle permet de travailler sans générer de texte, de localiser des couches et de comparer des variantes d'un encodeur. Cependant, l'espace n'est pas un inventaire transparent des « croyances » du modèle. Une direction peut agréger plusieurs facteurs. Les résultats doivent être décrits comme associations dans une représentation donnée, non comme opinions du système.

6.2 WEAT

WEAT définit deux ensembles de cibles X et Y et deux ensembles d'attributs A et B [17]. Pour chaque cible w , la fonction d'association calcule la différence entre la similarité moyenne à A et celle à B . La statistique de test agrège les associations de X et Y . La taille d'effet standardise la différence des moyennes par l'écart-type sur l'union des cibles. Un test de permutation échange les cibles entre X et Y pour estimer la probabilité d'une statistique au moins aussi extrême sous une hypothèse d'échangeabilité.

$$s(w,A,B) = \text{mean}_{a \in A} \cos(w,a) - \text{mean}_{b \in B} \cos(w,b)$$

$$d = [\text{mean}_{x \in X} s(x,A,B) - \text{mean}_{y \in Y} s(y,A,B)] / \text{sd}_{w \in X \cup Y} s(w,A,B)$$

Dans l'étude genre-profession, X et Y peuvent contenir des prénoms prétestés ou des termes explicitement genrés ; A et B , des mots liés à la carrière et à la famille. L'interprétation du signe dépend de l'ordre des ensembles. Pour éviter les erreurs, le notebook devra stocker la convention dans les métadonnées et inclure un test synthétique dont le signe est connu. La p -value de permutation doit être accompagnée de d et d'un intervalle de confiance bootstrap.

La petite taille des listes historiques fragilise les estimations. Un mot ambigu ou rare peut déplacer fortement le score. Le protocole prévoit trois jeux de stimuli : une réplique stricte des listes fondatrices, une version française validée, et une liste métier adaptée au contexte d'entreprise sans données confidentielles. Les analyses principales et de sensibilité resteront séparées. Créer après observation une liste qui maximise l'effet invaliderait le test confirmatoire.

6.3 SEAT et représentations contextualisées

SEAT applique l'idée de WEAT à des phrases [19]. Chaque stimulus est inséré dans plusieurs patrons, puis encodé. La représentation de phrase peut provenir du token [CLS], d'une moyenne des tokens ou d'un encodeur dédié. Ces choix ne sont pas neutres. [CLS] est entraîné différemment selon le modèle ; la moyenne mélange mots fonctionnels et stimulus ; le dernier état d'un modèle causal privilégie le contexte gauche.

Le protocole fixe une représentation principale cohérente avec l'architecture : pooling documenté par le modèle pour les sentence transformers, moyenne masquée des tokens non spéciaux pour un encodeur générique, et dernière position pertinente pour un modèle causal uniquement en analyse exploratoire. Une analyse multivers compare couches et pooling sans sélectionner rétrospectivement la variante favorable. La dispersion entre patrons est rapportée comme une information, pas réduite à une nuisance.

SEAT a l'avantage d'injecter un contexte, mais les phrases dites neutres peuvent être pragmatiquement étranges. En français, l'accord peut révéler le genre ou créer une discordance. Chaque patron sera évalué par au moins deux locuteurs et un score de naturalité. Les patrons rejetés seront documentés avant l'exécution principale.

6.4 CEAT et variation contextuelle

CEAT construit une distribution d'effets à partir d'occurrences naturelles [21]. Chaque échantillon de contextes produit une taille d'effet ; une combinaison à effets aléatoires tient compte d'une hétérogénéité entre contextes. Cette méthode rapproche la mesure de la variabilité réelle, mais son résultat dépend du corpus d'où proviennent les contextes. Un corpus journalistique, des offres d'emploi et des dialogues ne représentent pas le même usage.

Dans l'extension confirmatoire du benchmark, CEAT constitue un complément et non le critère principal, car il nécessite un corpus maîtrisé et augmente le coût. Il pourra comparer un corpus général public à un corpus synthétique de situations professionnelles. Aucune donnée interne ou personnelle ne devra être introduite dans un modèle externe. La provenance, la licence et le nettoyage des textes devront être enregistrés.

6.5 Propriétés scientifiques et limites

Les tests d'association ont une statistique définie, un mécanisme de permutation et une taille d'effet. Ces propriétés justifient leur inclusion dans un mémoire scientifique. Elles ne garantissent pas la validité sociale. La permutation suppose que les cibles sont échangeables sous l'hypothèse nulle ; les listes de prénoms peuvent porter des informations d'origine ou de génération. Les multiples combinaisons de couches, attributs et langues exigent une correction de multiplicité.

Une mesure embedding-based est surtout diagnostique. Elle peut aider à comparer des versions d'un même modèle, à rechercher une structure résiduelle après mitigation et à formuler des hypothèses. Elle ne doit pas décider seule du déploiement. Pour un modèle fermé, elle peut être impossible ; pour un modèle génératif aligné, elle peut surestimer le biais visible ; pour un classifieur en aval, elle peut ne pas prédire les écarts de performance [35].

Choix fondateur — WEAT [17] est retenu comme réplique de référence et SEAT [19] comme extension contextualisée principale. CEAT [21] est prévu en analyse complémentaire lorsque des contextes contrôlés sont disponibles.

7. Méthodes fondées sur les probabilités

7.1 Objet mesuré

Une méthode probability-based interroge la distribution du modèle sur des alternatives contrôlées. Elle répond à une question du type : à contexte constant, quelle variante le modèle juge-t-il la plus probable ? La manipulation contrefactuelle remplace un marqueur de genre tout en conservant le reste. Si les phrases sont équivalentes selon l'usage, une différence systématique constitue un signal de biais conditionnel.

Cette famille est plus proche du comportement prédictif que les embeddings, mais elle n'est pas identique à la génération. Une différence de log-probabilité faible peut s'accumuler ; une préférence locale peut être neutralisée par une instruction ; une réponse peut être refusée. Les probabilités sont aussi sensibles à la calibration et à la tokenisation. Le protocole conserve donc les scores continus et évite de réduire toute paire à un vote binaire.

7.2 LPBS

LPBS compare la probabilité d'un terme de genre dans un patron contenant un attribut avec sa probabilité dans un patron de référence [22]. La normalisation vise à retirer un prior global : si « il » est généralement plus probable que « elle », l'association avec « médecin » ne doit pas être confondue avec cette fréquence de base. Pour deux cibles i et j, le score est une différence de logarithmes de rapports.

$$LPBS(a;i,j) = \log[p(i \mid \text{contexte}(a)) / p(i \mid \text{contexte neutre})] - \log[p(j \mid \text{contexte}(a)) / p(j \mid \text{contexte neutre})]$$

Le choix du contexte neutre est décisif. Un double masque peut être traité différemment d'un simple masque ; l'ordre de remplissage peut créer une dépendance. Le français ajoute l'élision et l'accord. Le notebook devra afficher les tokens exacts et exclure, dans l'analyse principale, les cibles fragmentées de façon non comparable. Une analyse par somme de log-probabilités sur plusieurs tokens pourra compléter ce noyau.

LPBS est retenu pour les modèles masqués ouverts, notamment parce qu'il possède une définition claire et une histoire dans l'évaluation du biais de genre. Pour les modèles causaux, une variante basée sur la probabilité de séquences complètes sera utilisée et nommée distinctement afin de ne pas prétendre reproduire exactement LPBS.

7.3 Pseudo-log-vraisemblance et CrowS-Pairs

La pseudo-log-vraisemblance d'un modèle masqué est obtenue en cachant successivement chaque token et en additionnant la log-probabilité du token observé conditionnellement aux autres [24]. Deux phrases peuvent alors être comparées. Il faut décider quels tokens scorer. Inclure le terme identitaire peut faire dominer sa fréquence ; l'exclure peut supprimer une partie du signal. Les variantes seront explicitées.

$$PLL(S) = \sum_i \log p(\theta(s_i) \mid S \text{ sans } s_i)$$

Le score CrowS-Pairs est souvent le pourcentage de paires pour lesquelles la phrase stéréotypée reçoit une PLL supérieure. Une valeur proche de 50 % est interprétée comme absence de préférence globale. Mais ce taux ignore l'amplitude et peut mélanger des catégories. Le protocole rapporte le taux, la distribution de ΔPLL , la médiane, l'intervalle bootstrap et les résultats par sous-groupe.

Les critiques de qualité de CrowS-Pairs imposent une inspection. Les exemples de genre seront filtrés selon des règles préenregistrées : grammaticalité, différence minimale, stéréotype identifiable, absence de changement sémantique parasite. Le résultat sur le jeu original sera conservé pour comparabilité ; le résultat sur le sous-ensemble audité sera rapporté séparément.

7.4 StereoSet et compromis avec la capacité linguistique

StereoSet associe une continuation stéréotypée, une anti-stéréotypée et une option non pertinente [25]. Le Language Modeling Score mesure la préférence pour les options cohérentes, tandis que le Stereotype Score mesure la préférence entre stéréotype et anti-stéréotype. Un score synthétique tente de valoriser à la fois la capacité et l'équité. Ce dispositif répond à un problème réel : un modèle aléatoire peut obtenir une apparence de neutralité.

Un score composite impose toutefois une pondération normative et peut masquer deux modèles très différents. Le protocole conservera les composantes séparées et considérera le score global comme descriptif secondaire. Les exemples de profession et de genre seront analysés distinctement. Une baisse du Stereotype Score accompagnée d'une chute du score linguistique ne sera pas interprétée comme une amélioration sans réserve.

7.5 BBQ et contexte ambigu

BBQ offre une logique particulièrement adaptée à l'entreprise : lorsque l'information manque, le système doit reconnaître l'incertitude plutôt que compléter avec un stéréotype ; lorsque l'information est présente, il doit l'utiliser [26]. Les scores de biais sont examinés avec l'exactitude, dans les contextes ambigus et désambiguïsés. Cette séparation permet de distinguer ignorance, recours au stéréotype et incapacité générale.

Le format multiple-choice peut être évalué par log-probabilités ou génération de réponse. Les deux modalités peuvent diverger parce que le modèle génère une explication, suit mal l'étiquette ou refuse. Le protocole testera un sous-ensemble par les deux voies quand l'accès le permet. La comparaison elle-même devient un indicateur de validité de l'interface d'évaluation.

7.6 Contrôles statistiques

Les paires contrefactuelles appellent une analyse appariée. L'unité n'est pas chaque token, mais la paire ou le scénario. Un test de permutation apparié échange les étiquettes de genre au sein de chaque paire. Un bootstrap par scénario préserve la dépendance entre variantes. Pour des professions répétées dans plusieurs patrons, un modèle à effets mixtes peut inclure des intercepts aléatoires pour profession et template.

Le protocole privilégie les tailles d'effet et intervalles de confiance. Une différence significative sur des milliers de paires peut être négligeable ; une différence importante sur un petit sous-groupe peut manquer de puissance. Les tests exploratoires seront corrigés par Benjamini-Hochberg, tandis que les hypothèses confirmatoires limitées pourront utiliser un seuil familial plus strict.

Choix fondateur — LPBS [22] constitue la mesure principale pour les modèles masqués. CrowS-Pairs [24], StereoSet [25] et BBQ [26] apportent respectivement paires minimales, contrôle de capacité linguistique et raisonnement sous ambiguïté.

8. Méthodes fondées sur les générations

8.1 Pourquoi observer le texte produit

Une génération est le point de contact avec l'utilisateur. Elle permet d'auditer un modèle sans accès aux poids et d'observer des formes de biais qui ne se réduisent pas à une alternative préséparée : ton paternaliste, attribution de traits, omission, sexualisation, recommandation ou refus. Cette validité écologique relative explique la place croissante des audits generation-based.

Le prix est une variance élevée. La sortie dépend du prompt, de l'historique, du modèle aligné, du décodage et parfois de services externes. L'espace des textes possibles est immense. Une expérience doit définir l'unité, répéter les générations et séparer le comportement modal du risque de queue. Le protocole ne demandera jamais au modèle de « montrer son biais » comme seule condition : ce type d'instruction mesure surtout la conformité aux règles de sécurité.

8.2 Prompts contrefactuels

Le cœur du plan est une paire de prompts identiques sauf pour le marqueur de genre. Par exemple, un profil synthétique peut décrire les mêmes compétences avec un prénom féminin ou masculin, puis demander une synthèse, une proposition de trajectoire ou une lettre de recommandation. Le prompt doit être pertinent pour un usage autorisé et ne doit pas automatiser une décision réelle. Les profils restent fictifs.

Chaque scénario possède plusieurs paraphrases pour estimer la sensibilité. L'ordre des genres est randomisé. En conversation multi-tour, l'historique est réinitialisé entre paires. Les modèles sont interrogés avec le même rôle système dans la mesure du possible. Les API, versions et dates sont enregistrées. Les prompts français ne sont pas de simples traductions : ils sont adaptés puis alignés sémantiquement.

8.3 Regard, sentiment et toxicité

Le regard introduit par Sheng et al. évalue l'attitude envers le groupe référencé [28]. Il est plus pertinent que le sentiment brut pour distinguer un récit négatif d'un jugement négatif sur la personne. Un classifieur de regard peut produire des catégories positif, neutre et négatif. Le protocole utilise les probabilités si elles sont disponibles et mesure

la différence appariée entre genres.

La toxicité est utile pour RealToxicityPrompts et BOLD [29], [30], mais elle ne couvre pas les stéréotypes subtils. Un texte peut être poli et néanmoins attribuer moins de leadership. Inversement, un texte peut citer une insulte afin de la condamner. Le classifieur doit être considéré comme un capteur imparfait. Une partie stratifiée des sorties sera annotée humainement afin d'estimer précision et disparités du juge.

HONEST compte des complétions appartenant à un lexique blessant [31]. Sa disponibilité en français est un avantage. Les limites des lexiques — flexion, polysémie, négation, récupération d'un terme — seront documentées. Les scores lexicaux ne seront pas agrégés avec le regard comme s'ils partageaient une échelle.

8.4 Traits, professions et recommandations

Pour le biais de genre en contexte professionnel, des métriques ciblées complètent les classifieurs génériques. Les sorties peuvent être analysées selon la présence de termes liés au leadership, à la compétence, à la chaleur, à la prudence, à la famille ou à l'apparence. Les lexiques seront issus de travaux publiés puis adaptés par validation. Une méthode par embeddings de phrases peut mesurer la similarité avec des descriptions prototypes, mais elle réintroduit un juge vectoriel et doit être signalée comme telle.

Les recommandations nécessitent une grille humaine. Deux profils équivalents devraient recevoir des niveaux comparables de responsabilité, de rémunération hypothétique ou de formation. Cependant, demander directement une décision d'embauche serait éthiquement et juridiquement sensible. Le benchmark peut utiliser des scénarios de reformulation et de développement professionnel, sans alimenter un processus réel. La finalité est de détecter un comportement, non de déléguer une décision.

8.5 Refus, longueur et style

Le taux de refus est calculé séparément. Une taxonomie distingue refus explicite, réponse évasive, avertissement suivi d'une réponse, et réponse complète. La longueur, la richesse lexicale, le nombre de qualificatifs et le degré de certitude sont mesurés. Ces variables peuvent révéler une asymétrie de service même lorsque le sentiment reste neutre.

Les mesures de style sont sensibles au contenu. Une réponse plus longue n'est pas automatiquement meilleure. Le protocole vérifie l'utilité par une grille aveugle sur un échantillon. Les annotateurs ne voient pas le genre du profil lorsque son masquage est possible. L'ordre est randomisé et l'accord interannotateurs est rapporté par κ de Cohen ou α de Krippendorff selon le nombre d'annotateurs et le type de variable.

8.6 Répétition et décodage

Deux régimes sont proposés. Le régime déterministe utilise température nulle ou décodage glouton lorsque l'API le permet, avec une exécution répétée pour détecter une non-déterminisme serveur. Le régime stochastique utilise un réglage commun, par exemple $T = 0,7$ et $\text{top-p} = 0,9$, avec plusieurs seeds pour les modèles locaux. Les valeurs exactes seront fixées avant l'étude pilote.

La probabilité empirique d'au moins une sortie nuisible parmi k générations augmente mécaniquement avec k . Elle ne doit être comparée qu'à k constant. Le protocole rapporte aussi la moyenne par prompt et la distribution, afin d'éviter un indicateur dominé par le nombre de tirages. Pour les API sans seed, l'heure et l'identifiant de requête sont enregistrés ; la reproductibilité devient alors procédurale plutôt que bit à bit.

8.7 Juges humains et modèles juges

Un LLM peut évaluer des sorties selon une grille, mais il possède ses propres biais et une sensibilité à l'ordre. Il ne doit pas être la seule vérité terrain. Si un LLM-juge est utilisé, le prompt d'évaluation, la version, l'ordre des réponses et une validation humaine sont publiés. Les comparaisons par paires inversent l'ordre pour détecter un biais de position.

L'annotation humaine requiert consentement, consignes, possibilité de retrait et gestion des contenus difficiles. Les désaccords ne sont pas seulement du bruit : ils peuvent révéler une ambiguïté normative. Le rapport présentera la distribution des jugements et des exemples anonymisés, plutôt qu'une moyenne sans contexte.

Choix fondateur — Le protocole reprend le regard de Sheng et al. [28], les prompts naturels de BOLD [30], le volet multilingue de HONEST [31] et la couverture de HolisticBias [32]. RealToxicityPrompts [29] sert au contrôle du risque toxique, non à une définition exhaustive du biais de genre.

9. Synthèse critique et justification des méthodes retenues

9.1 Trois niveaux, trois questions

Les méthodes embedding-based demandent : quelles associations sont encodées dans les représentations ? Les méthodes probability-based demandent : entre des formulations contrôlées, lesquelles reçoivent le plus de probabilité ? Les méthodes generation-based demandent : que produit le système sous une politique d'interaction donnée ? Ces questions sont liées mais non interchangeables. La triangulation est scientifique précisément parce qu'elle conserve cette distinction.

Une chaîne plausible relie représentation, probabilité et génération, mais elle n'est pas déterministe. Les couches finales, l'instruction et le décodage transforment le signal. Une contradiction n'invalide pas automatiquement une mesure. Si WEAT détecte une association alors que la génération reste symétrique, l'alignement peut contenir l'expression ou WEAT peut manquer de validité. Si la génération diverge sans association détectable, le benchmark d'embedding peut observer la mauvaise couche ou la différence peut provenir du prompt.

9.2 Pourquoi ces méthodes sont qualifiées de scientifiques

Le qualificatif « scientifique » ne repose pas sur l'existence d'une formule seule. Les méthodes choisies satisfont plusieurs critères : objet mesurable, procédure explicite, hypothèse falsifiable, répétabilité, quantification de l'incertitude, comparaison avec des références et possibilité de critique. WEAT possède une statistique et un test de permutation ; LPBS et PLL définissent des scores probabilistes ; les audits de génération définissent un échantillonnage et des observables.

Ces propriétés restent conditionnelles. Un classifieur opaque, une liste de mots non publiée ou un prompt choisi après observation affaiblissent la scientificité. Le protocole ajoute donc préenregistrement, versionnage, publication des stimuli, seeds, intervalles de confiance et analyses de sensibilité. La transparence de la chaîne de mesure importe autant que la sophistication de la métrique.

9.3 Refus d'un score unique

Un score global séduirait la gouvernance, mais demanderait de normaliser et pondérer des objets hétérogènes. Une moyenne de WEAT, taux de préférences et toxicité n'a pas d'unité interprétable. Elle permettrait en outre une compensation : une bonne performance sur une famille masquerait un risque important sur une autre. Le mémoire recommande un profil multidimensionnel et des seuils liés à l'usage.

La décision peut s'appuyer sur des règles : absence de défaut critique confirmé par annotation, stabilité des résultats, écarts bornés sur une tâche pertinente, qualité minimale et plan de surveillance. Ces règles sont organisationnelles et

doivent être approuvées par les parties prenantes. Elles ne sont pas déduites mécaniquement de la littérature.

9.4 Menaces à la validité

La validité interne est menacée par les différences de longueur, accord, fréquence, tokenisation et naturalité. La validité externe l'est par la sélection des modèles, des langues et des usages. La validité de conclusion est menacée par la pseudo-réplication et la multiplicité. La validité de construit est menacée lorsque sentiment ou toxicité servent de substituts universels au biais.

La réponse n'est pas d'éliminer toute imperfection, objectif impossible, mais de rendre les menaces visibles et de tester la robustesse. Chaque résultat principal sera accompagné d'au moins une analyse de sensibilité. Les cas où le signe change seront considérés comme instables et ne soutiendront pas une conclusion forte.

9.5 Positionnement par rapport à la mitigation

Le mémoire porte sur la détection et l'évaluation. Les techniques de mitigation — augmentation contrefactuelle, projection, fine-tuning, contraintes de logits, prompting ou post-traitement — sont discutées comme contexte, mais non évaluées sans expérience. Les critiques de Gonen et Goldberg [18] montrent qu'optimiser la métrique utilisée pour l'entraînement peut seulement déplacer le signal. Toute mitigation future devra être évaluée sur des métriques non utilisées dans son objectif et sur une tâche aval.

Une bonne procédure suit un schéma avant/après avec même protocole, puissance suffisante et contrôle de qualité. La réduction du biais ne doit pas être achetée par une perte générale de compétence ou une augmentation des refus. Les résultats devront préciser quels préjudices sont réduits, pour quels groupes et dans quelles conditions.

10. Étude expérimentale pilote reproductible

10.1 Questions de recherche et statut de l'expérience

L'expérience opérationnalise cinq questions. RQ1 examine les associations entre marqueurs de genre et attributs de carrière, de famille, de science et d'arts dans les représentations. RQ2 mesure les préférences conditionnelles des modèles masqués et causaux sur des paires contrôlées. RQ3 recherche des différences dans les textes générés : leadership, compétence, référence au soin, polarité de genre, contenu blessant, refus et divergence sémantique. RQ4 compare les profils produits par les trois familles. RQ5 étudie la sensibilité aux modèles, aux patrons et au décodage.

Le notebook joint au travail a été exécuté intégralement, sans cellule en erreur, sur un GPU NVIDIA A100-SXM4 de 40 Go. Il emploie toutefois le profil **smoke**, conçu pour valider la chaîne de calcul à coût maîtrisé : 2 000 permutations, 2 000 répliquions bootstrap, six paires probabilistes et, pour la génération, trois scénarios croisés avec deux seeds. Les résultats ci-dessous sont donc des résultats pilotes réels. Ils permettent de vérifier la faisabilité, de repérer des signaux et de préparer une étude de puissance ; ils ne permettent ni de certifier un modèle ni de conclure à l'absence générale de biais.

Principe d'interprétation — Toutes les estimations rapportées proviennent de l'exécution fournie. Une non-significativité après correction FDR signifie seulement qu'aucun effet n'a été détecté avec ce plan pilote ; elle ne constitue pas une preuve d'équité.

Tableau 5 — Hypothèses préenregistrées et règles de décision recommandées.

Hypothèse	Formulation testable	Test principal	Décision
H1	Les associations genre–profession différent de zéro	Permutation WEAT/SEAT + IC bootstrap	Rejet si p ajustée < 0,05 et effet substantiel
H2	Le modèle préfère les formulations stéréotypées	Test apparié sur Δ log-probabilité	IC de la médiane excluant zéro
H3	Le genre modifie le regard ou les traits générés	Permutation appariée / modèle mixte	Effet robuste aux prompts et seeds
H4	Les métriques des trois familles convergent	Corrélations de Spearman avec IC	Analyse descriptive, sans causalité
H5	Le classement des modèles résiste aux variations	Analyse de sensibilité multivers	Stabilité du rang et du signe

10.2 Plan comparatif 3 × 3

Le plan retient trois modèles de taille croissante dans chaque famille. Pour les embeddings, multilingual-E5 small, base et large offrent une série cohérente d’encodeurs multilingues [42]. Pour les probabilités masquées, DistilmBERT multilingue, mBERT-base et XLM-R-large couvrent des capacités et des tailles différentes. Pour les générations, Qwen2.5-Instruct 0,5B, 1,5B et 3B forment une échelle homogène de modèles causaux ouverts ; leur architecture et leur couverture multilingue sont documentées dans le rapport Qwen2.5 [43]. Cette sélection favorise la comparabilité au sein d’une famille, sans prétendre isoler causalement l’effet de la taille : données, architecture et entraînement différent également entre certaines familles.




Figure 1 — Dispositif expérimental : trois familles et trois tailles de modèle par famille. Source : notebook expérimental.

Tableau 8 — Registre des neuf modèles exécutés dans le plan comparatif 3 × 3.

Famille	Taille	Modèle	Paramètres	Rôle expérimental	
Embeddings	Petite	E5-small	118 M	WEAT, SEAT, juge sémantique	
Embeddings	Moyenne	E5-base	278 M	WEAT, SEAT	
Embeddings	Grande	E5-large	560 M	WEAT, SEAT	
Probabilités	Petite	DistilmBERT	134 M	LPBS, AUL, AULA, PLL	
Probabilités	Moyenne	mBERT-base	177 M	LPBS, AUL, AULA, PLL	
Probabilités	Grande	XLM-R-large	560 M	LPBS, AUL, AULA, PLL	
Générations	Petite	Qwen2.5-0.5B-Instruct	494 M	SBS causal et générations	
Générations	Moyenne	Qwen2.5-1.5B-Instruct	1,54 Md	SBS causal et générations	
Générations	Grande	Qwen2.5-3B-Instruct	3,09 Md	SBS causal et générations	



Les modèles masqués servent aux scores LPBS, AUL, AULA et PLL. Les modèles Qwen sont évalués à la fois par log-probabilités causales sur paires et par générations contrefactuelles. Les encodeurs E5 sont réservés aux mesures géométriques ; E5-small sert aussi de juge de similarité pour la divergence sémantique. Ce dernier réemploi crée une dépendance méthodologique : la métrique de génération n'est pas indépendante de la famille embedding-based.

10.3 Paramètres, stimuli et traçabilité

La seed globale est fixée à 2026. Les générations utilisent un échantillonnage à température 0,8, top-p 0,95 et une longueur maximale de 64 nouveaux tokens. Les seeds 11 et 23 sont exécutées dans le profil pilote. Le calcul est réalisé en précision float16 lorsque le modèle et le matériel le permettent. Le notebook journalise le matériel, les versions, les paramètres, les temps, les sorties brutes et les tables intermédiaires. Il sépare registre des modèles, métriques, inférence, statistiques et visualisation.

Les stimuli reposent sur des listes de termes féminins et masculins, des attributs carrière/famille et science/arts, des patrons phrastiques pour SEAT, des professions pour LPBS et des paires contrefactuelles pour AUL, AULA, PLL et le score causal. Le volet génération manipule le genre à scénario constant. Cette symétrie réduit les facteurs concurrents, mais le faible nombre de patrons et la binarisation du contraste limitent la validité externe.

Tableau 4 — Architecture du protocole expérimental reproductible proposé.

Bloc	Entrées	Sorties	Contrôles obligatoires
Embeddings	Stimuli genre, attributs métier/famille/compétence	Effet WEAT/SEAT, p-value, bootstrap	Couche, pooling, langue, fréquence, seed
Probabilités	Paires minimales et patrons masqués	LPBS, PLL, taux de préférence	Tokenisation, longueur, prior, calibration
Générations	Prompts contrefactuels FR/EN	Regard, toxicité, traits, refus, diversité	Température, top-p, seed, répétitions, ordre
Synthèse	Tous les résultats et métadonnées	Profil par modèle et cas d'usage	Pas de score unique sans pondération justifiée

Tableau 7 — Checklist minimale de reproductibilité.

Élément	Minimum à publier	
Modèle	Nom exact, révision, taille, type base/instruct, quantification, tokenizer	
Environnement	Versions Python et bibliothèques, matériel, précision numérique, locale	
Prompts	Texte intégral, langue, ordre, gabarit système, exemples few-shot	
Décodage	Température, top-p/top-k, longueur maximale, stop tokens, seeds	
Mesures	Formules, agrégation, seuils, classifieurs auxiliaires et versions	
Statistiques	N, unités indépendantes, IC, tests, correction multiplicité, tailles d'effet	
Échecs	Refus, sorties vides, erreurs API, valeurs manquantes et règles d'exclusion	

10.4 Résultats fondés sur les embeddings

Les trois encodeurs E5 sont soumis à deux contrastes, carrière/famille et science/arts, avec WEAT puis SEAT. Aucun des douze tests ne rejette l'hypothèse nulle après correction du taux de fausses découvertes. Tous les intervalles bootstrap à



95 % recouvrent zéro. Les valeurs ne sont cependant pas uniformes : pour le contraste science/arts, WEAT vaut 0,763 avec E5-small, -0,489 avec E5-base et -0,485 avec E5-large ; les p-values brutes associées sont respectivement 0,124, 0,354 et 0,376. Pour carrière/famille, les effets WEAT sont -0,433, 0,155 et -0,123. Les estimations SEAT changent encore : 0,322, 0,608 et -0,099 pour carrière/famille.




Figure 2 — Effets WEAT et SEAT avec intervalles de confiance bootstrap à 95 %. Source : notebook expérimental.

Le résultat important n'est donc pas « aucun biais », mais l'instabilité de l'estimation au regard de la taille, du modèle et de la contextualisation. Le changement de signe entre E5-small et E5-base sur carrière/famille, ou entre E5-small et les modèles plus grands sur science/arts, interdit un classement simple. Avec des lexiques courts, les intervalles restent larges ; la puissance est insuffisante pour distinguer un petit effet d'un bruit d'échantillonnage. Cette observation confirme la critique formulée dans l'état de l'art : une géométrie d'association dépend du choix des stimuli et ne prédit pas à elle seule un comportement génératif [35].




Figure 3 — Sensibilité des mesures embedding-based au contexte et au patron. Source : notebook expérimental.

10.5 Résultats fondés sur les probabilités

Le LPBS révèle des profils plus contrastés. DistilBERT produit un score directionnel global de 0,133 ; XLM-R-large, 0,406 ; mBERT-base, -2,285. Pour ce dernier, les catégories science, soin et administration restent toutes négatives (-1,875 ; -2,426 ; -3,422). Le signe correspond à l'ordre de contraste programmé — masculin moins féminin après correction du prior — et doit être interprété avec cette convention. L'amplitude de mBERT constitue un signal descriptif à investiguer, non une comparaison directe de « quantité de biais » avec WEAT, car les échelles diffèrent.




Figure 4 — LPBS global et par domaine pour les trois modèles masqués. Source : notebook expérimental.

Sur six paires, les moyennes AUL, AULA et PLL ne conduisent à aucun rejet après FDR. DistilBERT présente AUL = 0,0767 et AULA = 0,0689 ; leurs intervalles bootstrap sont positifs, mais la permutation donne $p = 0,158$. Cette divergence entre intervalle bootstrap et test de permutation illustre la fragilité d'une inférence sur un très petit échantillon : la conclusion doit privilégier la transparence sur les deux procédures plutôt que sélectionner celle qui paraît la plus favorable. XLM-R-large est proche de zéro pour AUL et AULA, tandis que son PLL moyen vaut 0,115 ; mBERT-base présente AUL = -0,0185, AULA = -0,0178 et PLL = 0,0505. Aucun de ces résultats n'est concluant après correction.

Pour les Qwen, le score de biais séquentiel causal moyen est négatif pour les trois tailles : $-0,159$ (0,5B), $-0,231$ (1,5B) et $-0,217$ (3B). Les trois intervalles recouvrent zéro et les p-values valent respectivement 0,838, 0,442 et 0,372. La stabilité descriptive du signe ne compense pas l'incertitude statistique.




Figure 5 — Comparaison AUL, AULA et PLL avec incertitude pour les modèles masqués. Source : notebook expérimental.

10.6 Résultats fondés sur les générations

Chaque modèle Qwen produit douze générations, soit trois scénarios, deux variantes de genre et deux seeds. Les écarts sont calculés au niveau apparié. Les métriques de contenu blessant et de refus valent zéro pour les trois modèles dans ce pilote. Cette absence doit être lue comme « aucun cas détecté dans douze sorties », non comme une garantie de sûreté. Le plafonnement à 64 nouveaux tokens explique par ailleurs que la longueur de sortie varie peu et limite l'interprétation de cette métrique.

La polarité de genre présente des différences moyennes positives : 3,219 pour Qwen-0,5B, 4,682 pour Qwen-1,5B et 2,888 pour Qwen-3B. Les intervalles bootstrap sont entièrement positifs, mais les tests de permutation donnent $p = 0,132$ et aucune hypothèse n'est rejetée après FDR. Les scores de leadership sont $-0,388$, $0,017$ et $-0,820$; ceux de compétence 0,439, $-0,446$ et $-0,476$. Ces changements de signe montrent que la taille ne produit pas une amélioration monotone et que la métrique choisie modifie le classement.





Figure 6 — Effets appariés des métriques générationnelles par taille de Qwen2.5. Source : notebook expérimental.

Un modèle linéaire mixte exploratoire sur le score de leadership converge sur 36 observations, avec un intercept aléatoire par stimulus. Le coefficient de la variante masculine est $-0,397$, IC 95 % $[-0,961 ; 0,167]$, $p = 0,168$. Il ne permet pas de conclure à un effet de genre ; le faible nombre de groupes rend en outre l'approximation asymptotique fragile.

La divergence sémantique entre sorties appariées, mesurée avec E5-small, décroît descriptivement avec la taille : 0,112 pour Qwen-0,5B, 0,099 pour Qwen-1,5B et 0,072 pour Qwen-3B. Les intervalles bootstrap associés sont $[0,087 ; 0,143]$, $[0,073 ; 0,135]$ et $[0,056 ; 0,089]$. Cette tendance suggère que les grands modèles de la série produisent ici des réponses plus proches entre variantes, mais elle repose sur six comparaisons par modèle et sur un juge unique ; elle doit être répliquée avant toute attribution à la taille.



10.7 Coût de calcul et compromis opérationnel

Le débit médian diminue lorsque la taille augmente : 39,15 tokens/s pour Qwen-0,5B, 32,87 pour 1,5B et 25,70 pour 3B. La latence médiane progresse de 1,63 s à 1,95 s puis 2,49 s. Le pic mémoire observé passe d'environ 968 Mio à 2 966 Mio puis 6 015 Mio. Ces mesures ont été obtenues sur le même A100 et pour douze générations par modèle ; elles servent surtout à dimensionner le profil complet.

Tableau 9 — Performance observée du volet génération sur NVIDIA A100-SXM4 40 Go.

Modèle	N	Débit médian	Latence médiane	Pic GPU	Tokens/sortie	
Qwen2.5-0.5B	12	39,15 tok/s	1,63 s	968 Mio	64	
Qwen2.5-1.5B	12	32,87 tok/s	1,95 s	2 966 Mio	64	
Qwen2.5-3B	12	25,70 tok/s	2,49 s	6 015 Mio	64	




Figure 8 — Débit, latence et mémoire GPU du volet génération. Source : notebook expérimental.

Le modèle de 3B est donc plus coûteux, mais présente la plus faible divergence sémantique. Il n'est en revanche pas systématiquement meilleur sur leadership, compétence ou polarité de genre. Le compromis qualité-équité-coût doit rester multidimensionnel : une réduction sur une métrique ne compense pas automatiquement une dégradation sur une autre.

10.8 Synthèse comparative des neuf modèles

Tableau 10 — Synthèse 3 × 3 des métriques principales du profil pilote.

Famille	Modèle	Métrique de synthèse	Estimation [IC 95 %]	Lecture	
Embedding	E5-small	SEAT carrière/famille	0,322 [-0,831 ; 1,280]	IC recouvre 0	
Embedding	E5-base	SEAT carrière/famille	0,608 [-0,661 ; 1,525]	IC recouvre 0	
Embedding	E5-large	SEAT carrière/famille	-0,099 [-1,147 ; 1,251]	IC recouvre 0	
Probabilité	DistilmBERT	Écart moyen PLL	0,251 [-0,079 ; 0,554]	FDR : non rejeté	
Probabilité	mBERT-base	Écart moyen PLL	0,050 [-0,110 ; 0,208]	FDR : non rejeté	
Probabilité	XLM-R-large	Écart moyen PLL	0,115 [-0,075 ; 0,322]	FDR : non rejeté	
Génération	Qwen2.5-0.5B	Divergence sémantique	0,112 [0,087 ; 0,143]	Descriptif, n = 6	
Génération	Qwen2.5-1.5B	Divergence sémantique	0,099 [0,073 ; 0,135]	Descriptif, n = 6	

Génération	Qwen2.5-3B	Divergence sémantique	0,072 [0,056 ; 0,089]	Descriptif, n = 6
------------	------------	-----------------------	-----------------------	-------------------




Figure 9 — Vue de synthèse des neuf modèles et de leur métrique principale. Source : notebook expérimental.

La synthèse met en évidence trois conclusions. Premièrement, aucune hypothèse principale n'est rejetée après FDR dans le profil smoke. Deuxièmement, les estimations descriptives ne sont pas nulles et leurs signes ou amplitudes varient entre modèles et métriques. Troisièmement, aucune progression monotone avec la taille n'apparaît sur l'ensemble des familles. Le modèle le plus grand n'est donc pas automatiquement le moins biaisé, et le plus petit n'est pas systématiquement le plus risqué.

Il serait scientifiquement incorrect d'agréger ces résultats en une note unique. Les valeurs WEAT, LPBS, PLL, polarité et divergence n'ont ni la même unité ni la même relation avec un préjudice. La bonne unité de compte rendu est un profil : estimation, incertitude, statut après correction, contexte et exemples qualitatifs.

10.9 Menaces à la validité

La principale limite est la puissance. Six paires ou six observations générationnelles par modèle ne permettent pas d'estimer précisément des effets hétérogènes. Le bootstrap sur un si petit support peut produire des intervalles peu stables, et deux seeds ne caractérisent pas la distribution de décodage. La correction FDR protège contre les faux positifs mais réduit encore la puissance. Les résultats nuls ne doivent donc pas être transformés en preuve d'absence.

La validité de construit est également limitée. Les lexiques historiques représentent le genre de manière binaire ; les patrons artificiels n'épuisent pas le français professionnel ; les métriques automatiques de leadership ou de soin reposent sur des lexiques ; la divergence sémantique dépend d'E5-small. Enfin, la comparaison par taille est observationnelle : au sein de la famille probability-based, architecture, corpus et tokenizer changent en même temps que le nombre de paramètres.

10.10 Reproductibilité et passage au profil complet

Le notebook est organisé pour être relancé de haut en bas : seed globale, registres de modèles, configuration centralisée, tables exportables, statistiques appariées, correction de multiplicité, suivi du temps et de la mémoire. Il ne contient pas de données clients ou salariés de BNP Paribas. Les résultats présentés ont été repris automatiquement depuis ses sorties afin d'éviter une transcription sélective.

Le profil complet devra augmenter le nombre de stimuli et de seeds sur la base d'une analyse de puissance, figer les révisions des modèles et ajouter une annotation humaine en aveugle. Les variantes prévues — couches et pooling pour les embeddings, normalisation et patrons pour les probabilités, température et reformulations pour les générations — devront être déclarées avant lecture des résultats. Une réplication sur un second matériel et, si possible, une seconde implémentation de métrique permettra de distinguer signal de modèle et artefact logiciel.

Tableau 6 — Jeux de données candidats et précautions d'usage.

Ressource	Langue / cible	Famille	Apport	Réserve
WinoBias / Winogender	Anglais, professions	Probabilité/tâche	Paires de corréférence contrôlées	Cadre historiquement binaire

CrowS-Pairs	Anglais, 9 axes	Probabilité	Paires minimales	Qualité et validité de certains exemples contestées
StereoSet	Anglais, 4 axes	Probabilité	Contrôle de cohérence linguistique	Score agrégé délicat à interpréter
BBQ	Anglais, 9 axes	Probabilité/génération	Contextes ambigus et désambiguïsés	Contexte culturel états-unien
BOLD	Anglais, 5 domaines	Génération	Prompts naturels	Dépendance aux classifieurs auxiliaires
HONEST	6 langues dont français	Génération	Comparaison multilingue	Lexique des termes blessants incomplet
HolisticBias	Anglais + extension multilingue	Génération	Couverture démographique large	Combinaisons artificielles possibles

Un résultat futur sera qualifié de robuste seulement s'il associe une taille d'effet pertinente, une incertitude resserrée, un signe stable dans les analyses planifiées et une interprétation confirmée sur un échantillon humain. Le présent pilote satisfait la reproductibilité de la chaîne, mais pas encore ces conditions de robustesse substantielle.

11. Traduction dans un contexte d'entreprise et financier

11.1 Du benchmark au cas d'usage

Un score de laboratoire ne suffit pas à autoriser un usage. L'organisation doit d'abord cartographier la tâche : utilisateurs, personnes mentionnées, décisions influencées, données traitées, possibilité de recours et gravité d'une erreur. Un assistant de reformulation interne, un chatbot client et un outil de préparation de dossier n'ont pas le même profil de risque. Le protocole doit être adapté sans modifier après coup la définition du succès.

Dans le contexte de BNP Paribas, ce mémoire propose un cadre générique, non un audit institutionnel. Les exemples professionnels peuvent tester la rédaction inclusive, la synthèse symétrique de profils fictifs et la qualité de conseils généraux. Ils ne doivent pas utiliser de données clients, de salariés ou de documents internes dans un service externe. Les conclusions devront être validées par les fonctions compétentes avant tout usage réel.

11.2 Gouvernance du risque

Le NIST AI RMF recommande de gouverner, cartographier, mesurer et gérer les risques [39]. Pour le biais de genre, gouverner signifie attribuer responsabilités et critères d'escalade ; cartographier signifie relier groupe, contexte et préjudice ; mesurer signifie appliquer le protocole ; gérer signifie corriger, limiter, surveiller ou renoncer. L'évaluation n'est donc qu'une étape d'un cycle.

Le règlement européen sur l'intelligence artificielle établit un cadre fondé sur le risque [40]. Le présent mémoire ne fournit pas une analyse juridique et ne classe pas un système particulier. Il retient une implication opérationnelle prudente : documentation, qualité des données, supervision, traçabilité et maîtrise des risques doivent être pensées dès la conception, surtout lorsqu'un système peut influencer des personnes.

11.3 Seuils et décision

La littérature ne fournit pas un seuil universel de WEAT, LPBS ou toxicité garantissant l'acceptabilité. Un seuil doit dépendre du cas d'usage, d'une référence, de la puissance, du coût des erreurs et de l'avis des parties prenantes. Il peut être formulé comme non-infériorité par rapport à un système de référence, différence maximale acceptable sur une tâche ou absence de scénarios critiques confirmés.

La décision doit considérer l'intervalle d'incertitude. Si l'étude ne permet pas d'exclure un écart préoccupant, la conclusion correcte peut être « données insuffisantes ». Une approche mature autorise aussi le déploiement limité, avec humain dans la boucle et monitoring, ou interdit certaines fonctions. Le score ne remplace pas la responsabilité.

11.4 Surveillance continue

Les modèles, prompts et bases documentaires évoluent. Un audit ponctuel devient obsolète après un changement de version. Le protocole doit donc être intégré à des tests de non-régression : sous-ensemble rapide à chaque modification et campagne complète périodique. Les dérives de taux de refus, de qualité et de disparité sont suivies.

Les remontées utilisateurs constituent une autre source, mais elles ne forment pas un échantillon représentatif. Un canal de signalement, une taxonomie des incidents et une revue humaine complètent les métriques. Les incidents graves doivent déclencher une analyse de cause : données récupérées, prompt, modèle, filtre ou interface.

11.5 Limites de l'automatisation de l'audit

Automatiser le benchmark favorise la répétition, mais peut donner une fausse assurance. Un tableau de bord vert ne prouve pas que les personnes affectées jugent le système équitable. Les métriques doivent rester reliées à des exemples et à une analyse qualitative. Les personnes concernées et experts de domaine doivent participer à la définition des scénarios.

L'objectif n'est pas de rendre le modèle « aveugle au genre » dans tous les cas. Il est d'éviter des associations et traitements injustifiés tout en conservant l'information légitime. Cette nuance est indispensable dans une organisation où les cas d'usage diffèrent et où la neutralisation totale peut dégrader la précision ou effacer des besoins spécifiques.

12. Discussion, limites et perspectives

12.1 Ce que le protocole permet d'établir

Le protocole peut établir qu'un modèle, dans une version et des conditions définies, présente une association, une préférence probabiliste ou une différence comportementale liée à des marqueurs de genre. Il peut comparer des modèles et tester la robustesse. Il peut repérer un désaccord entre niveaux et fournir des exemples vérifiables. Il crée enfin une base reproductible pour évaluer une mitigation.

Il ne peut pas démontrer l'absence universelle de biais, prédire tous les usages ou transformer une mesure linguistique en preuve juridique de discrimination. Il ne capture pas automatiquement les effets organisationnels. Une étude de terrain, des audits de décisions et une consultation des personnes affectées sont nécessaires lorsque le système intervient réellement dans une allocation.

12.2 Limites du mémoire

Ce travail associe une revue critique, un protocole implémenté et une étude pilote. Les résultats sont réels, mais l'effectif



du profil smoke ne fournit pas la puissance requise pour une conclusion confirmatoire. Le mémoire assume cette séparation : les valeurs observées servent à contrôler le pipeline, apprécier les ordres de grandeur et préparer le profil complet ; elles ne sont pas présentées comme une validation d'usage.

Le périmètre textuel limite la généralisation aux images. Le français est intégré au protocole mais moins doté en benchmarks validés que l'anglais. Le noyau binaire, nécessaire pour répliquer des travaux historiques, reste une simplification ; le module non binaire ne résout pas à lui seul les enjeux d'inclusion. Enfin, les API propriétaires évoluent et réduisent la reproductibilité.

12.3 Passage du pilote au benchmark confirmatoire

Le notebook modulaire est désormais opérationnel : il calcule WEAT/SEAT, LPBS, AUL/AULA/PLL, scores causaux, métriques générationnelles, bootstrap, permutations, correction de multiplicité et visualisations. La prochaine étape n'est donc plus de construire la preuve de concept, mais d'étendre le plan sans modifier rétrospectivement les hypothèses à partir des résultats pilotes.

Le profil confirmatoire devra augmenter les paires et les scénarios, employer davantage de seeds, intégrer des données françaises validées et conduire une annotation humaine à l'aveugle. Une analyse de puissance fondée sur des effets minimaux pertinents — plutôt que sur les seules estimations instables du pilote — déterminera les effectifs. Les sorties resteront exportées avec leurs métadonnées et reliées aux figures par un manifeste reproductible.

12.4 Perspectives scientifiques

Un axe important consiste à relier les métriques aux usages. Plutôt que chercher seulement une corrélation globale, on peut construire un modèle causal de la chaîne : association interne, probabilité, génération, jugement humain et décision. Des interventions sur le prompt ou les représentations permettent d'étudier quelles composantes modifient effectivement le préjudice.

La participation des communautés concernées doit aussi progresser. Les benchmarks communautaires comme WinoQueer montrent une voie [33]. Pour le genre en français et en contexte professionnel, une co-construction pourrait identifier des stéréotypes contemporains, des formes indirectes et des critères d'utilité. Cela améliorerait la validité de construit plus sûrement qu'une multiplication automatique de templates.

Enfin, l'évaluation devrait devenir longitudinale. Un modèle mis à jour peut améliorer une métrique et se dégrader sur une autre. Un registre de versions, des cartes de modèle et des tests réguliers permettent de distinguer progrès réel, déplacement du biais et simple apprentissage du benchmark.

Conclusion générale

Les biais de genre dans les modèles d'intelligence artificielle générative ne forment ni une propriété unique ni un nombre directement observable. Ils apparaissent comme associations dans les représentations, préférences dans les distributions et comportements dans les générations. Les travaux fondateurs — de Bolukbasi et WEAT à SEAT, LPBS, CrowS-Pairs, StereoSet, Sheng, BOLD, HONEST et HolisticBias — ont fourni des instruments essentiels. Les critiques ont montré leurs limites : sensibilité aux choix, binarisation du genre, défauts de benchmarks et faible lien automatique avec les usages.

Le choix des trois familles embedding-based, probability-based et generation-based est donc justifié par une complémentarité d'objets et d'accès. Leur caractère scientifique dépend de la rigueur du protocole : hypothèses définies, stimuli publiés, facteurs contrôlés, unités statistiques correctes, incertitude quantifiée, analyses de sensibilité et interprétation circonscrite. Aucune valeur isolée ne certifie l'équité.

Pour un contexte d'entreprise, et notamment pour réfléchir à des usages dans le secteur financier, l'audit doit rester relié

au cas d'usage, à la qualité et à la gouvernance. L'étude pilote 3 × 3 montre concrètement pourquoi : aucune hypothèse n'est rejetée après FDR, mais les estimations changent de signe ou d'amplitude selon la famille, le modèle et le patron ; la divergence sémantique décroît avec la taille des Qwen alors que les autres métriques ne suivent pas une amélioration monotone. Ces observations ne certifient aucun modèle. Elles établissent surtout la faisabilité de la triangulation et identifient les dimensions à renforcer dans un benchmark confirmatoire. L'enjeu est moins de déclarer un modèle « débiaisé » que de construire une preuve pluraliste, traçable et révisable de son comportement.

Références

- [1] A. Vaswani et al., "Attention Is All You Need," in *Advances in Neural Information Processing Systems* 30, 2017, pp. 5998–6008. [Accès en ligne](#)
- [2] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," in *Proc. NAACL-HLT*, 2019, pp. 4171–4186, doi: 10.18653/v1/N19-1423. [Accès en ligne](#)
- [3] T. B. Brown et al., "Language Models are Few-Shot Learners," in *Advances in Neural Information Processing Systems* 33, 2020, pp. 1877–1901. [Accès en ligne](#)
- [4] R. Bommasani et al., "On the Opportunities and Risks of Foundation Models," *arXiv:2108.07258*, 2021. [Accès en ligne](#)
- [5] S. L. Blodgett, S. Barocas, H. Daumé III, and H. Wallach, "Language (Technology) is Power: A Critical Survey of 'Bias' in NLP," in *Proc. ACL*, 2020, pp. 5454–5476, doi: 10.18653/v1/2020.acl-main.485. [Accès en ligne](#)
- [6] S. L. Blodgett, G. Lopez, A. Olteanu, R. Sim, and H. Wallach, "Stereotyping Norwegian Salmon: An Inventory of Pitfalls in Fairness Benchmark Datasets," in *Proc. ACL-IJCNLP*, 2021, pp. 1004–1015, doi: 10.18653/v1/2021.acl-long.81. [Accès en ligne](#)
- [7] S. Dev et al., "Harms of Gender Exclusivity and Challenges in Non-Binary Representation in Language Technologies," in *Proc. EMNLP*, 2021, pp. 1968–1994, doi: 10.18653/v1/2021.emnlp-main.150. [Accès en ligne](#)
- [8] H. Devinney, J. Björklund, and H. Björklund, "Theories of 'Gender' in NLP Bias Research," in *Proc. ACM FAccT*, 2022, pp. 2083–2102, doi: 10.1145/3531146.3534627. [Accès en ligne](#)
- [9] T. Sun et al., "Mitigating Gender Bias in Natural Language Processing: Literature Review," in *Proc. Workshop on Gender Bias in NLP*, 2019, pp. 163–170, doi: 10.18653/v1/W19-3824. [Accès en ligne](#)
- [10] J. Zhao, T. Wang, M. Yatskar, V. Ordonez, and K.-W. Chang, "Gender Bias in Coreference Resolution: Evaluation and Debiasing Methods," in *Proc. NAACL-HLT*, 2018, pp. 15–20, doi: 10.18653/v1/N18-2003. [Accès en ligne](#)
- [11] R. Rudinger, J. Naradowsky, B. Leonard, and B. Van Durme, "Gender Bias in Coreference Resolution," in *Proc. NAACL-HLT*, 2018, pp. 8–14, doi: 10.18653/v1/N18-2002. [Accès en ligne](#)
- [12] V. Gautam, A. Subramonian, A. Lauscher, and O. Keyes, "WINOPRON: Revisiting English Winogender Schemas for Consistency, Coverage, and Grammatical Case," in *Proc. CRAC*, 2024. [Accès en ligne](#)
- [13] M. De-Arteaga et al., "Bias in Bios: A Case Study of Semantic Representation Bias in a High-Stakes Setting," in *Proc. ACM FAT**, 2019, pp. 120–128, doi: 10.1145/3287560.3287572. [Accès en ligne](#)
- [14] I. O. Gallegos et al., "Bias and Fairness in Large Language Models: A Survey," *Computational Linguistics*, vol. 50, no. 3, pp. 1097–1179, 2024, doi: 10.1162/coli_a_00524. [Accès en ligne](#)
- [15] Z. Chu, Z. Wang, and W. Zhang, "Fairness in Large Language Models: A Taxonomic Survey," *ACM SIGKDD Explorations Newsletter*, vol. 26, no. 1, pp. 34–48, 2024, doi: 10.1145/3682112.3682117. [Accès en ligne](#)
- [16] T. Bolukbasi, K.-W. Chang, J. Y. Zou, V. Saligrama, and A. T. Kalai, "Man is to Computer Programmer as Woman is to Homemaker? Debiasing Word Embeddings," in *Advances in Neural Information Processing Systems* 29, 2016. [Accès en ligne](#)

[17] A. Caliskan, J. J. Bryson, and A. Narayanan, "Semantics Derived Automatically from Language Corpora Contain Human-like Biases," *Science*, vol. 356, no. 6334, pp. 183–186, 2017, doi: 10.1126/science.aal4230. [Accès en ligne](#)

[18] H. Gonen and Y. Goldberg, "Lipstick on a Pig: Debiasing Methods Cover up Systematic Gender Biases in Word Embeddings But do not Remove Them," in *Proc. NAACL-HLT*, 2019, pp. 609–614, doi: 10.18653/v1/N19-1061. [Accès en ligne](#)

[19] C. May, A. Wang, S. Bordia, S. R. Bowman, and R. Rudinger, "On Measuring Social Biases in Sentence Encoders," in *Proc. NAACL-HLT*, 2019, pp. 622–628, doi: 10.18653/v1/N19-1063. [Accès en ligne](#)

[20] N. Garg, L. Schiebinger, D. Jurafsky, and J. Zou, "Word Embeddings Quantify 100 Years of Gender and Ethnic Stereotypes," *Proc. National Academy of Sciences*, vol. 115, no. 16, pp. E3635–E3644, 2018, doi: 10.1073/pnas.1720347115. [Accès en ligne](#)

[21] W. Guo and A. Caliskan, "Detecting Emergent Intersectional Biases: Contextualized Word Embeddings Contain a Distribution of Human-like Biases," in *Proc. AAAI/ACM AIES*, 2021, doi: 10.1145/3461702.3462536. [Accès en ligne](#)

[22] K. Kurita, N. Vyas, A. Pareek, A. W. Black, and Y. Tsvetkov, "Measuring Bias in Contextualized Word Representations," in *Proc. Workshop on Gender Bias in NLP*, 2019, pp. 166–172, doi: 10.18653/v1/W19-3823. [Accès en ligne](#)

[23] K. Webster, X. Wang, I. Tenney, A. Beutel, E. Pitler, E. Pavlick, J. Chen, and S. Petrov, "Measuring and Reducing Gendered Correlations in Pre-trained Models," *arXiv:2010.06032*, 2020. [Accès en ligne](#)

[24] N. Nangia, C. Vania, R. Bhalerao, and S. R. Bowman, "CrowS-Pairs: A Challenge Dataset for Measuring Social Biases in Masked Language Models," in *Proc. EMNLP*, 2020, pp. 1953–1967, doi: 10.18653/v1/2020.emnlp-main.154. [Accès en ligne](#)

[25] M. Nadeem, A. Bethke, and S. Reddy, "StereoSet: Measuring Stereotypical Bias in Pretrained Language Models," in *Proc. ACL-IJCNLP*, 2021, pp. 5356–5371, doi: 10.18653/v1/2021.acl-long.416. [Accès en ligne](#)

[26] A. Parrish et al., "BBQ: A Hand-Built Bias Benchmark for Question Answering," in *Findings of ACL*, 2022, pp. 2086–2105, doi: 10.18653/v1/2022.findings-acl.165. [Accès en ligne](#)

[27] M. Bartl, M. Nissim, and A. Gatt, "Unmasking Contextual Stereotypes: Measuring and Mitigating BERT's Gender Bias," in *Proc. Workshop on Gender Bias in NLP*, 2020, pp. 1–16, doi: 10.18653/v1/2020.gebnlp-1.1. [Accès en ligne](#)

[28] E. Sheng, K.-W. Chang, P. Natarajan, and N. Peng, "The Woman Worked as a Babysitter: On Biases in Language Generation," in *Proc. EMNLP-IJCNLP*, 2019, pp. 3407–3412, doi: 10.18653/v1/D19-1339. [Accès en ligne](#)

[29] S. Gehman, S. Gururangan, M. Sap, Y. Choi, and N. A. Smith, "RealToxicityPrompts: Evaluating Neural Toxic Degeneration in Language Models," in *Findings of EMNLP*, 2020, pp. 3356–3369, doi: 10.18653/v1/2020.findings-emnlp.301. [Accès en ligne](#)

[30] J. Dhamala et al., "BOLD: Dataset and Metrics for Measuring Biases in Open-Ended Language Generation," in *Proc. ACM FAccT*, 2021, pp. 862–872, doi: 10.1145/3442188.3445924. [Accès en ligne](#)

[31] D. Nozza, F. Bianchi, and D. Hovy, "HONEST: Measuring Hurtful Sentence Completion in Language Models," in *Proc. NAACL-HLT*, 2021, pp. 2398–2406, doi: 10.18653/v1/2021.naacl-main.191. [Accès en ligne](#)

[32] E. M. Smith et al., "I'm Sorry to Hear That: Finding New Biases in Language Models with a Holistic Descriptor Dataset," in *Proc. EMNLP*, 2022, pp. 9180–9211, doi: 10.18653/v1/2022.emnlp-main.625. [Accès en ligne](#)

[33] V. Felkner, H.-C. Chang, E. Jang, and J. May, "WinoQueer: A Community-in-the-Loop Benchmark for Anti-LGBTQ+ Biases in Large Language Models," in *Proc. ACL*, 2023, pp. 9126–9140, doi: 10.18653/v1/2023.acl-long.507. [Accès en ligne](#)

[34] D. Esiobu et al., "ROBBIE: Robust Bias Evaluation of Large Generative Language Models," in *Proc. EMNLP*, 2023, pp. 3764–3814, doi: 10.18653/v1/2023.emnlp-main.230. [Accès en ligne](#)

[35] S. Goldfarb-Tarrant, R. Marchant, R. Muñoz Sánchez, M. Pandya, and A. Lopez, "Intrinsic Bias Metrics Do Not

Correlate with Application Bias,” in Proc. ACL-IJCNLP, 2021, pp. 1926–1940, doi: 10.18653/v1/2021.acl-long.150. [Accès en ligne](#)

[36] P. Delobelle, E. Tokpo, T. Calders, and B. Berendt, “A Comparative Study of Fairness-Enhanced Pre-trained Language Models,” in Proc. NAACL-HLT, 2022, pp. 1656–1670, doi: 10.18653/v1/2022.naacl-main.122. [Accès en ligne](#)

[37] M. Pikuliak, A. Beňová, and M. Šimko, “In-Depth Look at Word Filling Societal Bias Measures,” in Proc. EACL, 2023, pp. 3648–3665, doi: 10.18653/v1/2023.eacl-main.265. [Accès en ligne](#)

[38] H. Orgad and Y. Belinkov, “How Gender Debiasing Affects Internal Model Representations, and Why It Matters,” in Proc. NAACL-HLT, 2022, pp. 2602–2628, doi: 10.18653/v1/2022.naacl-main.188. [Accès en ligne](#)

[39] E. Tabassi, “Artificial Intelligence Risk Management Framework (AI RMF 1.0),” NIST AI 100-1, National Institute of Standards and Technology, 2023, doi: 10.6028/NIST.AI.100-1. [Accès en ligne](#)

[40] European Parliament and Council, “Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence,” Official Journal of the European Union, 2024. [Accès en ligne](#)

[41] M. Kaneko and D. Bollegala, “Unmasking the Mask — Evaluating Social Biases in Masked Language Models,” in Proc. AAAI Conf. Artificial Intelligence, vol. 36, no. 11, pp. 11954–11962, 2022, doi: 10.1609/aaai.v36i11.21453. [DOI](#)

[42] L. Wang et al., “Multilingual E5 Text Embeddings: A Technical Report,” arXiv:2402.05672, 2024. [Accès en ligne](#)

[43] A. Yang et al., “Qwen2.5 Technical Report,” arXiv:2412.15115, 2024. [Accès en ligne](#)