



DÉTECTION ET ÉVALUATION DES BIAIS DE GENRE

30/08/2026

dans les modèles d'intelligence artificielle générative

Mémoire de fin d'études — Master 2 Vision et Machine Intelligente

Université Paris Cité — Alternance chez BNP Paribas, RHG / People AI

Sofiane Agouni Kaci

Tuteur pédagogique : Sylvain Lobry — Tutrice en entreprise : Imane Loukah



BNP PARIBAS

La banque d'un monde qui change

SOMMAIRE



- 1** Contexte et problématique
- 2** Méthode et protocole expérimental
- 3** Résultats
- 4** Discussion et conclusion





CONTEXTE DE L'ALTERNANCE ET PROBLÉMATIQUE





Le terrain : RHG et People AI

Une alternance de Data Scientist au cœur des Ressources Humaines Groupe

People AI est le centre d'expertise IA des Ressources Humaines du Groupe. Sa mission : accompagner le déploiement d'une IA responsable dans les activités RH.



Une équipe mixte

Data Scientists et AI Business Analysts, en lien avec l'AI Factory côté IT Groupe.



Des processus sensibles

Recrutement, gestion des compétences, mobilité, formation, satisfaction des collaborateurs.



Mon rôle

Data Scientist en alternance, encadré par Imane Loukah, Lead Data Scientist.



Une contrainte de départ

Qualité des données, traçabilité, sécurité : l'IA responsable n'est pas une option en banque.





Trois missions pendant l'alternance

Trois sujets distincts, un même fil conducteur : la fiabilité de ce que produit un modèle



ASSISTANT CODEUR

Assistant IA génératif dédié au code, pour aider les Data Scientists, Data Engineers et Data Analysts dans leurs tâches de développement.



CLASSIFICATION NLP

Normalisation et classification de données textuelles RH : structurer du texte libre pour le rendre exploitable par les métiers.



BIAIS DES MODÈLES

Biais sur données structurées et non structurées. C'est ce troisième sujet qui a donné naissance au mémoire, recentré sur les LLM.





Du terrain au sujet de mémoire

Pourquoi le biais de genre, et pourquoi le texte

Les LLM s'intègrent déjà à de nombreux usages métier — rédaction, synthèse, extraction d'information. En RH, ils touchent des processus qui engagent directement des personnes.



Des données non neutres

Un LLM reproduit les régularités de ses données d'entraînement, où les rôles sociaux sont représentés inégalement.



Un enjeu concret en RH

Un modèle génératif peut résumer un profil, identifier des compétences ou recommander un poste.



Un périmètre borné

Le seul biais de genre, sur du texte, avec des modèles open source accessibles dans l'écosystème du Groupe.



Ni audit, ni données internes

Le mémoire n'évalue aucun système BNP Paribas et n'utilise ni données clients, ni données collaborateurs.





Comment détecter et quantifier, de façon scientifique et reproductible, le biais de genre d'un modèle génératif ?

Les résultats varient selon le niveau observé, le protocole, le prompt, la langue et le contexte d'usage.





Qu'est-ce qu'un biais de genre ?

Du biais statistique au préjudice social

LE BIAIS, UN MOT POLYSÉMIQUE

- **Le mot « biais » change de sens selon le domaine : écart statistique, hypothèse du modèle, ou erreur systématique**
- Ici, le sujet est le biais social : une différence entre groupes n'est pas automatiquement injuste
- Mais un système bien calibré peut tout de même reproduire une situation défavorable
- Le mémoire retient : une différence systématique liée à des marqueurs de genre, qui signale un risque de stéréotypie ou de traitement inéquitable

STÉRÉOTYPE ET ÉQUITÉ

- **Un stéréotype attribue un rôle à un groupe — même une association jugée positive peut limiter les rôles proposés**
- Un modèle apprend des cooccurrences et ne distingue pas décrire d'un corpus vs prescrire un comportement
- Le genre n'est pas binaire : il mêle des dimensions sociales, identitaires, linguistiques et grammaticales
- La mesure quantitative est un indicateur de ce construit — pas le construit lui-même





MÉTHODE ET PROTOCOLE EXPÉRIMENTAL





Trois niveaux d'analyse

Trois questions différentes, complémentaires



EMBEDDINGS

Associations dans l'espace de représentation. Diagnostic interne à faible coût, mais validité comportementale limitée.



PROBABILITÉS

Préférence entre formulations contrôlées. Paires reproductibles, mais sensibles à la tokenisation.



GÉNÉRATIONS

Texte effectivement produit par le modèle. Proche de l'usage réel, mais variance du décodage et coût plus élevé.



Lire un résultat statistique

Signification, amplitude et précision répondent à des questions différentes

p-value

rareté de l'effet sous H_0 ; elle ne mesure ni sa taille, ni la probabilité que H_0 soit vraie.

q-value

p-value ajustée pour la multiplicité des tests (Benjamini-Hochberg) ; le seuil retenu est $q < 0,05$.

IC à 95 %

plage d'effets compatible avec les données ; un intervalle qui traverse 0 reste incertain.

ÉCART ET TAILLE D'EFFET

$$\Delta = \frac{1}{n} \sum_{i=1}^n \delta_i \quad d_z = \frac{\Delta}{s_\delta}$$

P-VALUE PAR PERMUTATION

$$\hat{p} = \frac{1 + \#\{b : |T_b| \geq |T_{\text{obs}}|\}}{B + 1}$$

BOOTSTRAP ET BENJAMINI-HOCHBERG

$$\text{IC}_{95\%} = [q_{2,5\%}(\Delta^*) ; q_{97,5\%}(\Delta^*)]$$

$$q_{(i)} = \min\left(1, \min_{j \geq i} \frac{m}{j} p_{(j)}\right)$$



Mesurer une association vectorielle

WEAT et SEAT : la géométrie comme indice de biais

Une similarité, pas une vérité

$\cos(w, a)$ mesure la proximité entre un mot et un attribut dans l'espace vectoriel.

Une taille d'effet standardisée

d compare deux groupes de mots cibles X, Y sur leur association aux pôles A, B .

Un test de permutation

la significativité (p , puis q après FDR) est estimée en permutant les mots, pas en supposant une loi théorique.

ASSOCIATION D'UN MOT AVEC DEUX PÔLES D'ATTRIBUTS

$$s(w, A, B) = \text{mean}_{a \in A} \cos(w, a) - \text{mean}_{b \in B} \cos(w, b)$$

TAILLE D'EFFET (WEAT / SEAT)

$$d = \frac{\text{mean}_{x \in X} s(x, A, B) - \text{mean}_{y \in Y} s(y, A, B)}{\text{std}_{w \in X \cup Y} s(w, A, B)}$$

Exemple de contraste — carrière / famille :

$A = \{\text{executive, management, professional, corporation}\}$ vs $B = \{\text{home, children, family, marriage}\}$



SEAT : du mot à la phrase

Étendre WEAT à des mots mis en contexte

Un gabarit neutre

le mot w est inséré dans une phrase-gabarit t , par exemple « This is $\langle w \rangle$ » ou « $\langle w \rangle$ is here ».

Un encodeur de phrase

$\text{Enc}(w, t)$ encode la phrase entière, pas le mot seul — utile pour BERT et les modèles contextuels.

Même statistique que WEAT

la fragilité du gabarit devient elle-même une source de variance à contrôler (18 gabarits testés).

MÊME STATISTIQUE, APPLIQUÉE À L'ENCODAGE DE LA PHRASE

$$s(\hat{w}, A, B) = \text{mean}_{a \in A} \cos(\hat{w}, \hat{a}) - \text{mean}_{b \in B} \cos(\hat{w}, \hat{b})$$

avec $\hat{w} = \text{Enc}(w, t)$, $\hat{a} = \text{Enc}(a, t)$, $\hat{b} = \text{Enc}(b, t)$ — la phrase-gabarit encodée

Exemple de gabarits (SEAT) :

« This is $\langle w \rangle$ » · « $\langle w \rangle$ is here » · « I saw a $\langle w \rangle$ today »



Comparer des probabilités contrôlées

LPBS, PLL, AUL, AULA : le modèle préfère-t-il une formulation ?

LPBS

retire le prior global avant de comparer masculin et féminin dans un contexte donné.

PLL

masque chaque token à tour de rôle et additionne sa log-probabilité conditionnelle.

AUL et AULA

AUL évalue tous les tokens sans masquage ;
AULA pondère cette somme par l'attention portée à chaque token.

LPBS — PRIOR CORRIGÉ

$$\text{LPBS}(a) = \log \frac{p(m \mid c(a))}{p(m \mid c_0)} - \log \frac{p(f \mid c(a))}{p(f \mid c_0)}$$

PSEUDO-LOG-VRAISEMBLANCE (PLL)

$$\text{PLL}(S) = \sum_{i=1}^{|S|} \log p_{\theta}(s_i \mid S \setminus s_i)$$

AUL — SANS MASQUAGE

$$\text{AUL}(S) = \sum_{i=1}^{|S|} \log p_{\theta}(s_i \mid S)$$



Générations : mesurer le texte produit

Du texte libre à un score comparable entre deux prompts

Score lexical

proportion de mots d'un texte appartenant à un lexique donné (leadership, soin, compétence...).

Polarité de genre

équilibre entre mots masculins et féminins effectivement produits dans le texte.

Écart apparié

même statistique Δ , IC et q-value que pour les embeddings et les probabilités.

SCORE LEXICAL PAR CATÉGORIE

$$\text{Score}_c(T) = \frac{1}{|T|} \sum_{w \in T} \mathbf{1}[w \in L_c]$$

POLARITÉ DE GENRE DU TEXTE PRODUIT

$$\text{Pol}(T) = \frac{n_H(T) - n_F(T)}{n_H(T) + n_F(T)}$$

ÉCART APPARIÉ ENTRE PROMPTS CONTREFACTUELS

$$\Delta_M = M(S_H) - M(S_F)$$



Neuf modèles, trois familles

Un plan comparatif 3 × 3 — modèles open source, disponibles dans l'écosystème du Groupe

Embeddings


mMiniLM-L12, mE5-base, BGE-M3 — trois lignées et objectifs d'entraînement différents.

Probabilités

CamemBERT, mBERT, XLM-R-large — trois modèles masqués adaptés au français ou multilingues.

Générations

Qwen2.5-0.5B / 1.5B-Instruct, Mistral-7B-base — deux instruction-tuned et un modèle de base.



RÉSULTATS



Associations dans les embeddings

WEAT et SEAT sur trois encodeurs, six contrastes

33 tests sur 36


significatifs après correction FDR ($q < 0,05$)

Le contexte amplifie l'effet

surtout pour mE5-base et BGE-M3, entre WEAT et SEAT

Pas de lien net avec la taille

mMiniLM-L12 (118M) affiche la projection métiers la plus élevée



Probabilités : le LPBS par domaine

Trois modèles masqués, dix-huit activités professionnelles

Valeurs majoritairement négatives

un LPBS < 0 favorise les formulations féminines après correction du prior

mBERT, l'écart le plus marqué

parfois inférieur à -3, contre des valeurs plus modérées pour CamemBERT et XLM-R

Le signe change selon le domaine

une moyenne globale masquerait une partie des différences



Ce que produisent les modèles génératifs

768 textes par modèle, prompts contrefactuels appariés

La polarité de genre, seul effet robuste


positive et significative pour les trois modèles, partout

Rien d'autre après FDR

leadership, soin, compétence, refus, longueur : aucun écart corrigé significatif

Une exception mineure

Qwen2.5-0.5B : légèrement plus d'incertitude après un prompt masculin





Résultats en chiffres

Où lire l'écart Δ , son intervalle de confiance et sa significativité après correction FDR

Famille	Test / modèle	Δ (H – F)	IC à 95 %	q (FDR)	Lecture
Embeddings	WEAT + SEAT — 3 encodeurs × 6 contrastes	—	—	33/36 < 0,05	Associations nettes dans l'espace latent
Probabilités	PLL — CamemBERT	−0,136	[−0,269 ; 0,002]	≥ 0,05	Non significatif après correction
Probabilités	PLL — mBERT	−0,234	[−0,310 ; −0,160]	< 0,05	Formes féminines favorisées
Probabilités	PLL — XLM-R-large	−0,393	[−0,482 ; −0,310]	< 0,05	Formes féminines favorisées
Générations	Polarité de genre — 3 modèles	+0,78 à +2,25	—	< 0,05	Seul effet robuste ; reflète l'accord grammatical

Lecture : Δ et l'IC donnent l'amplitude, q (après correction FDR) la significativité ; un Δ négatif favorise la formulation féminine.







L'exécution en chiffres

Ce que donne à voir une exécution complète du protocole

-  **Des associations nettes dans les embeddings, mais qui ne suffisent pas à prévoir un usage réel.**
-  **Une préférence probabiliste qui dépend fortement du modèle et du domaine observé.**
-  **Aucun classement stable entre la taille d'un modèle et l'ampleur de ses biais.**





DISCUSSION ET CONCLUSION





Du benchmark au cas d'usage

Ce qu'une équipe comme People AI peut réellement réutiliser

Un bon score expérimental n'autorise pas un usage. Il faut d'abord décrire la tâche, les personnes concernées, les décisions influencées et les moyens de recours.

Des seuils fixés avant l'audit

Aucun seuil universel de WEAT ou de LPBS : il dépend du cas d'usage et du coût des erreurs.

Des métriques en fonctions

WEAT, SEAT, CEAT ; LPBS, PLL, AUL, AULA ; score lexical, polarité de genre, écart apparié.

Une base statistique commune

Bootstrap apparié, p-value par permutation et correction de Benjamini-Hochberg, réutilisables telles quelles.

Un outil, pas un service

Toute intégration réelle suppose une revue risque, conformité, sécurité et protection des données.





Limites et perspectives

Ce que le protocole ne démontre pas, et ce qui reste à construire

LIMITES

- Un contraste de genre binaire ; qualité variable de certaines formulations françaises
- Un corpus construit de situations professionnelles, quatre seeds de génération
- Le français dispose de moins de jeux d'évaluation validés que l'anglais

PERSPECTIVES

- Une co-construction communautaire pour des stéréotypes contemporains
- Un module dédié à l'intersectionnalité, séparé du benchmark de genre
- Une réévaluation dans le temps : une nouvelle version peut progresser sur une métrique et régresser sur une autre



Conclusion

Trois familles de mesures, un protocole, aucune certification d'équité

L'évaluation du biais de genre dépend de l'endroit où l'on regarde : espace latent, probabilités, ou générations

Trois familles complémentaires, aucune ne dominant partout

Leur valeur scientifique tient au protocole : hypothèses préenregistrées, facteurs contrôlés, incertitude mesurée

Aucun score pris seul ne certifie l'équité d'un modèle

L'objectif : des résultats vérifiables, contextualisés et révisables — pas une étiquette « débiaisé »



**MERCI DE VOTRE
ATTENTION
DES QUESTIONS ?**

