

Métrique	Famille	Accès technique nécessaire	Priorité	Pourquoi elle est dans le top 10
CEAT	Embedding-based	Embeddings contextualisés + banque de contextes	Haute	La meilleure option de la famille embedding pour prendre en compte la variabilité de contexte
Sentence Bias Score	Embedding-based	Embeddings phrase/mot	Haute	Très utile pour localiser le biais au niveau des mots qui “tirent” la phrase
SEAT	Embedding-based	Embeddings + templates	Complément	Bonne baseline canonique sentence-level, utile pour comparer
All Unmasked Likelihood	Probability-based	Log-probabilités token-level, surtout MLM	Très haute	Plus robuste que les métriques centrées sur un seul token masqué
Log-Probability Bias Score	Probability-based	Log-probabilités masked/token-level	Très haute	Normalisation par la probabilité prior, donc très interprétable
Categorical Bias Score	Probability-based	Log-probabilités masked/token-level	Haute	Extension multi-groupes de LPBS
HONEST	Generated-based	Texte généré + lexique	Très haute	Mesure directe des complétions blessantes et stéréotypées
Psycholinguistic Norms	Generated-based	Texte généré + lexiques VAD/BE5	Très haute	Multi-dimensionnel, au-delà du simple “toxique / non toxique”
Gender Polarity	Generated-based	Texte généré + lexique/embeddings	Haute	Très utile pour la polarité générée ; bonne corrélation humaine
Co-Occurrence Bias Score	Generated-based	Lot de générations + lexiques groupes/attributs	Complément	Excellent baromètre des associations répétées dans les sorties

TABLE 1 – Top 10 des métriques de détection de biais pour modèles génératifs